Inatel

Tópicos Avançados em IoT e Machine Learning

Mestrado e Doutorado em Telecomunicações

Profª. Victoria Dala Pegorara Souto

Motivação











→ Modelos mais Eficientes

- Os **avanços em IA** têm levado à criação de **grandes modelos** (como GPTs, DALL-E, Deep Seek, GroudingDINO, YOLOs entre outros), também chamados de foundational models.
- Esses modelos são usados para tradução de texto, assistência pessoal, detecção de objetos, geração de imagens, sons e vídeos sintéticos, etc.
- Para que tenham um **altíssimo desempenho**, esses modelos são **treinados em bases de dados massivas**.
- Além disso, devido à sua **complexidade e ao volume de parâmetros**, eles demandam **enormes recursos computacionais** – CPU, memória, armazenamento e energia – para treinamento e execução (também chamada de inferência).

Motivação







→ Modelos mais Eficientes

- Por exigirem **recursos computacionais colossais**, isso os torna **proibitivamente caros**.
- Como resultado, a maioria dos usuários os acessa como **serviços baseados em nuvem**.
- Entretanto, o uso na **nuvem** resulta em **maior latência, alto consumo de energia, custos operacionais elevados e menor segurança** com relação aos dados dos usuários.
- Essa realidade torna inviável o uso desses e outros modelos em dispositivos com recursos limitados, como smartphones, wearables ou dispositivos IoT.

Motivação



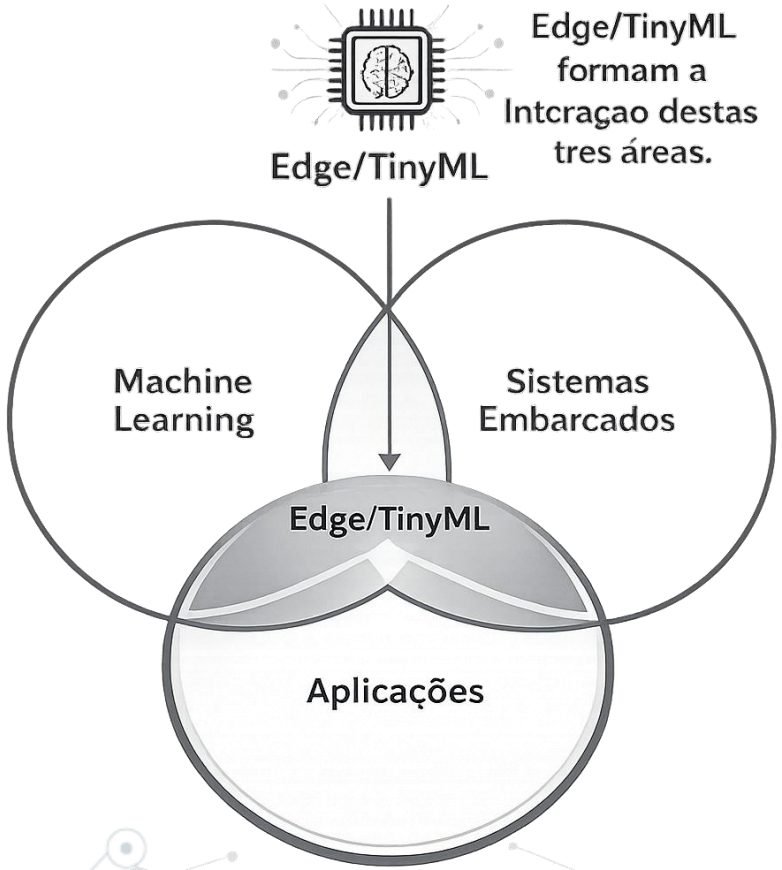




→ Modelos mais Eficientes

- Esses dispositivos são caracterizados por:
  - **Baixa capacidade de processamento:** microcontroladores ou processadores com poder de computação reduzido.
  - **Memória restrita:** pouca memória RAM e não volátil.
  - **Baixo consumo de energia:** devem ser energeticamente eficientes, sendo muitas vezes alimentados por baterias.
  - **Recursos de hardware simples:** dispõem de periféricos básicos e conectividade limitada.

Motivação

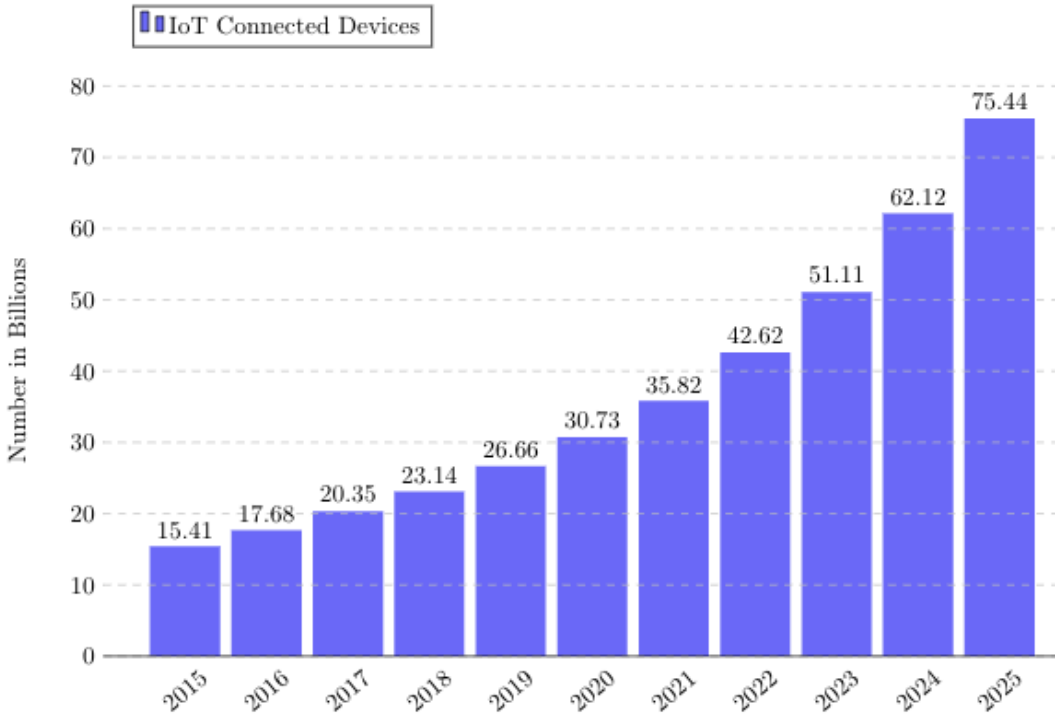


→ Modelos mais Eficientes

- Nesse contexto, surgem os paradigmas edge e tinyML.
- Eles buscam **adaptar técnicas de ML para ambientes restritos**, permitindo a implementação de **modelos otimizados e eficientes** que podem ser executados localmente com baixo consumo de energia e memória.
  - O tinyML também é conhecido como embeddedML.

Motivação

→ Número de Dispositivos Conectados





- Estima-se que teremos **mais de 75 bilhões de dispositivos** IoT até 2025.
- A grande maioria desses dispositivos estão **equipados com microprocessadores ou microcontroladores, (vários) sensores e atuadores**.

Motivação

→ Economia



NVIDIA Ampere
A100
Graphics Processing
Unit (GPU)
400 Watts
826 mm^2



Apple A12 (iPhone)
System on a chip
(SoC): CPUs, GPU e
Video Codec
3.64 Watts
83 mm^2



Apple APL0778
(iWatch)
Application Processor
Unit (APU):
CPU+GPU
< 0.78 Watts
32 mm^2

Tiny

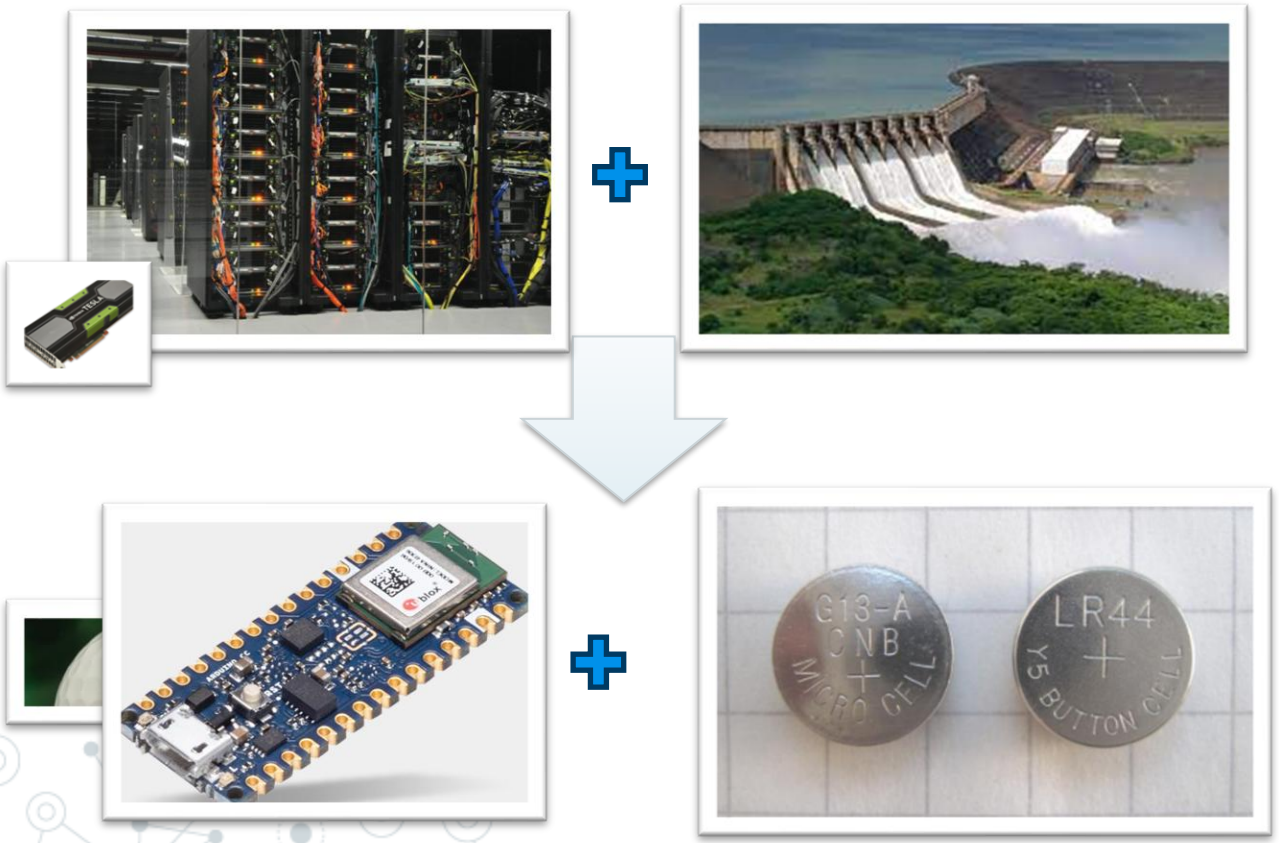


Syntiant NDP100
Neural Decision
Processor (NDP)
140 μWatts
2.52 mm^2

- Se comparados com servidores, equipados com dezenas de CPUs e GPUs, os **processadores e microcontroladores** desses dispositivos **são muito menores e consomem muito menos energia e são mais baratos**, devido a alta demanda.

Motivação

→ Baixo Consumo de Energia



O baixíssimo consumo de energia possibilita que os dispositivos:

- **Funcionem por longos períodos** de tempo sem trocar a bateria (e.g., anos);
- E executem aplicações "**Always On**":
  - ✓ **Aplicação constantemente ativa e monitorando o ambiente ao seu redor,** coletando informações, as processando e respondendo em tempo real, sem interrupção.
  - ✓ Característica muito importante em aplicações que exigem monitoramento constante, como sistemas de **segurança, monitoramento de saúde**, sistemas de **automação industrial** ou dispositivos de **assistência virtual**.

https://youtube.com/shorts/O8cmpRZ9dOo?feature=share

Motivação

→ Sensores

- Dispositivos IoT, também chamados de ***endpoints***, possuem muitas vezes uma grande variedade de sensores!

Sensores de movimento
Giroscópios, radares (e.g., LiDAR), magnetômetros, acelerômetros.

Sensores de acústicos
Microfones, ultrassônicos, vibrômetros, geofones.

Sensores ambientais
Temperatura, humidade, pressão, infra-vermelho.

Sensores de toque
Capacitivos e Resistivos.

Sensores de imagem
RGB, Térmicos, LiDAR.

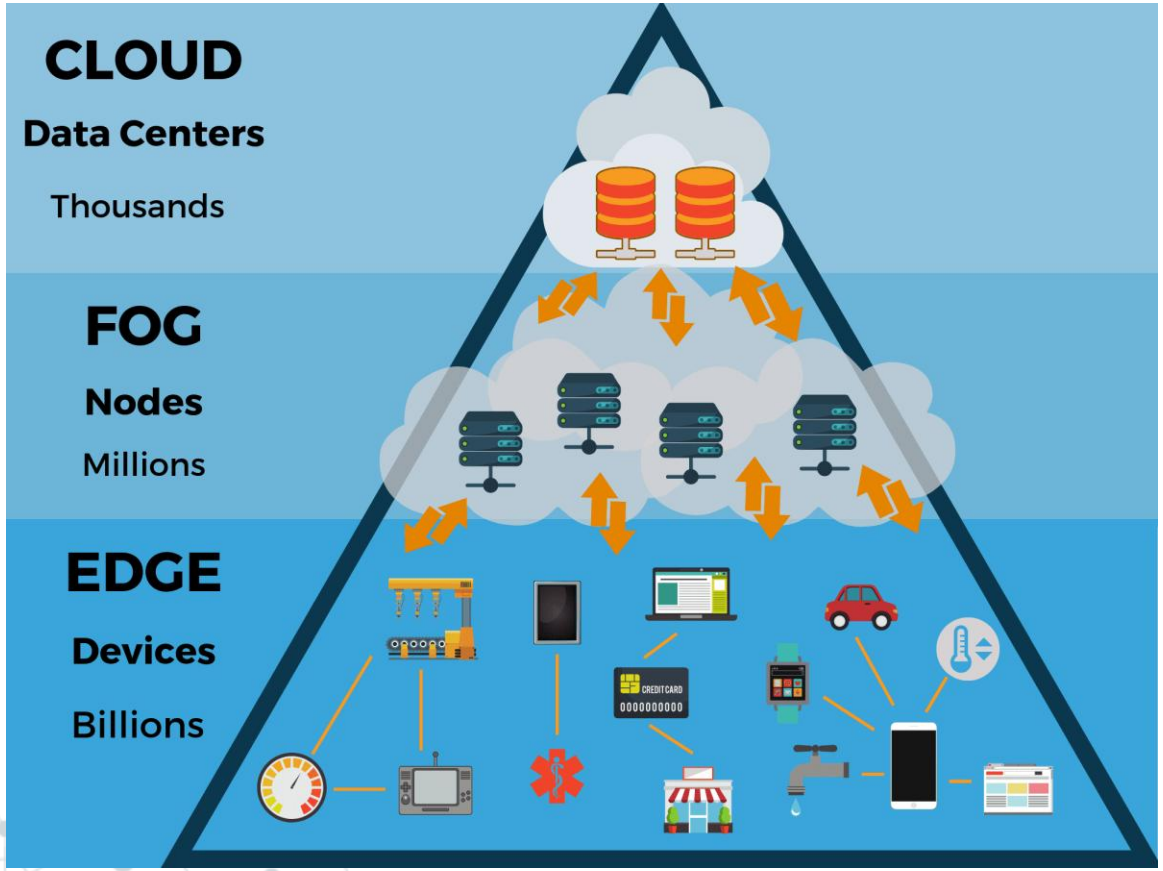
Sensores biométricos
impressão digital, batimento cardíaco, glicose.

Sensores de força
Pressão, deformação/tensão.

Sensores de rotação
Encoders rotativos, potenciômetros.

Motivação

→ Cloud vs Edge Computing



- **Cloud Computing**: os dados são coletados na borda e o processamento é feito em data centers, muitas vezes distribuídos ao longo de várias localizações.
- **Edge Computing**: processamento e armazenamento de dados é feito ***próximo ou nos dispositivos que coletam os dados*** (ou seja, na borda da rede).

Motivação

→ EdgeML vs TinyML



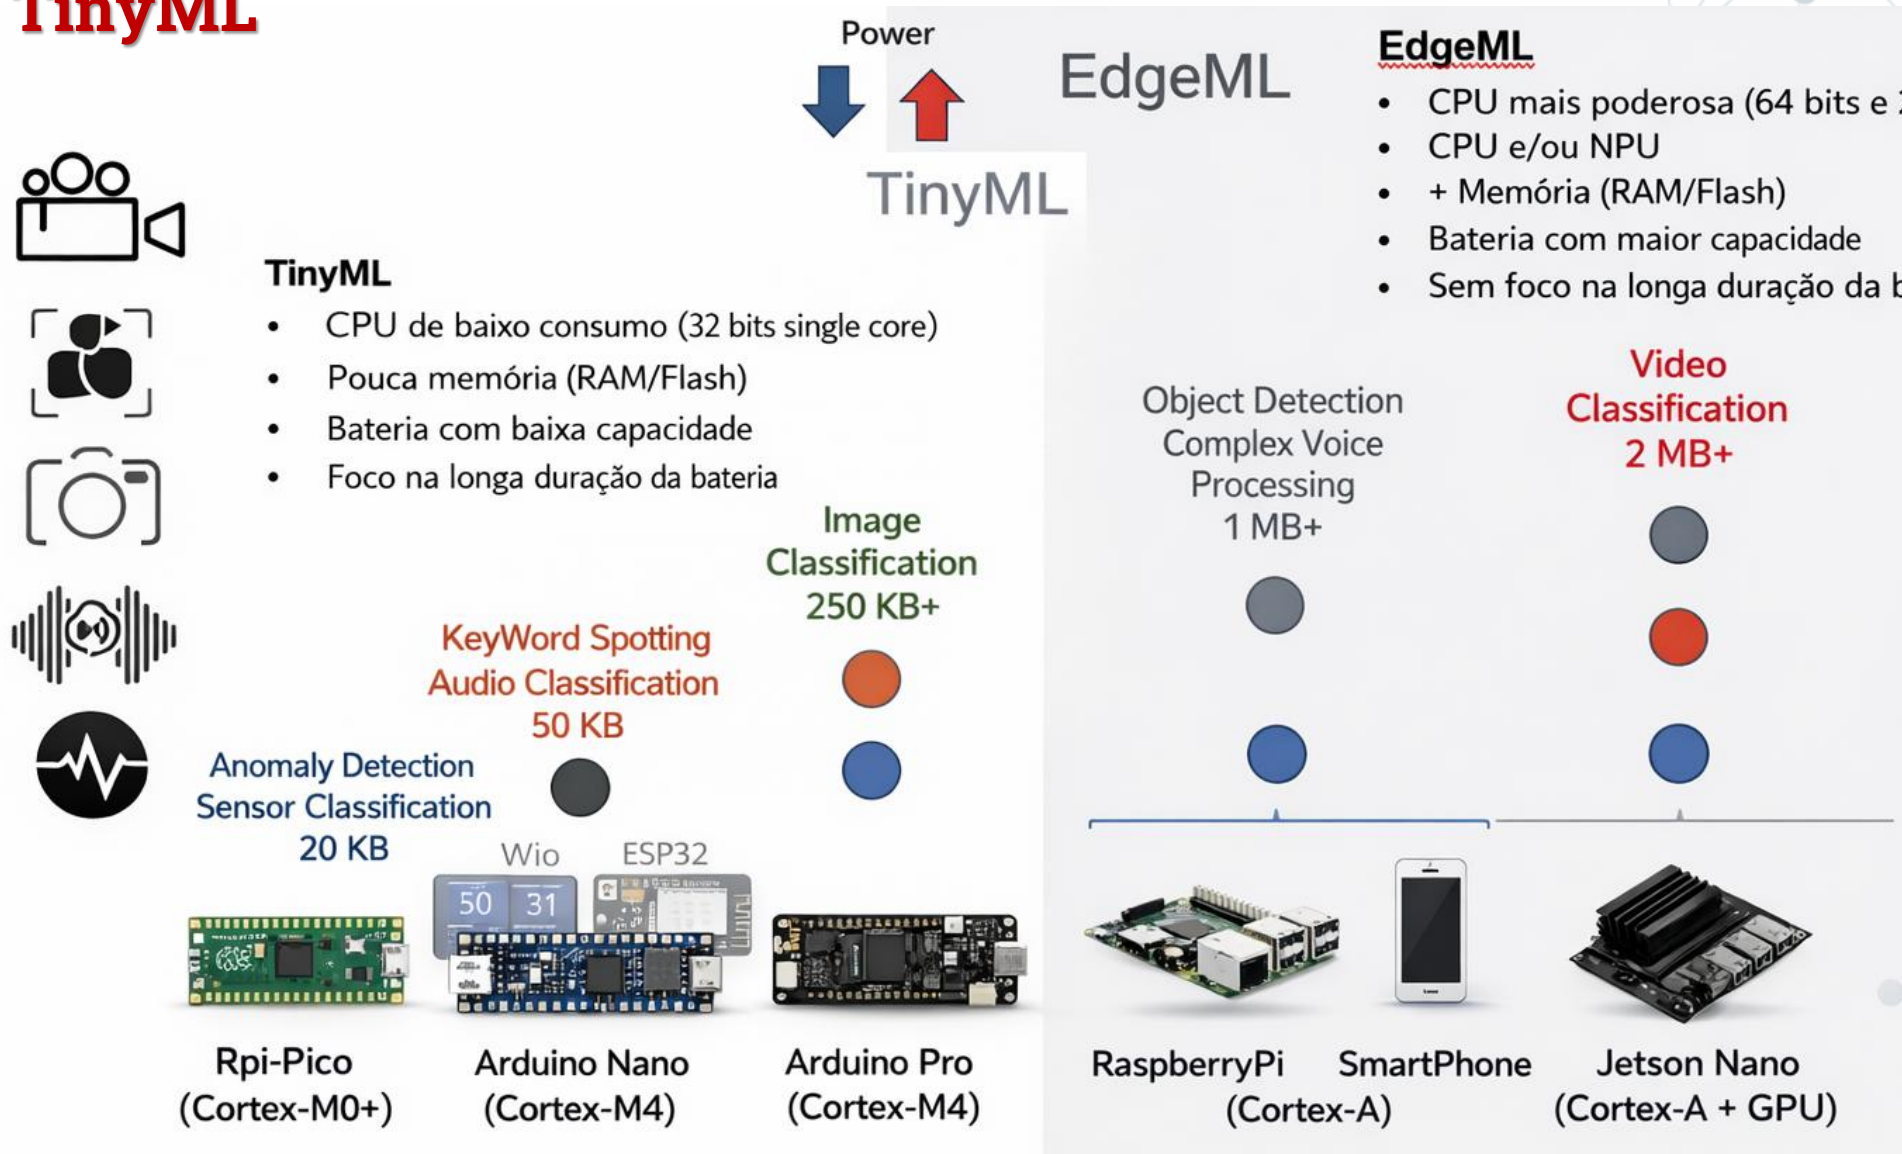
Nosso curso focará no uso de ambos os tipos de dispositivos.

- **EdgeML**: processamento de algoritmos de ML em **dispositivos de borda** (onde os dados são coletados ou gerados) **com recursos computacionais moderados**.
- **TinyML**: subconjunto do **EdgeML** onde os **dispositivos de borda possuem recursos computacionais bastante restritos**.
  - Dispositivos com **consumo de energia ultrabaixo** (alimentados por baterias).
  - Possibilitam **a execução contínua de modelos de ML** (i.e., dispositivos "**always on**").

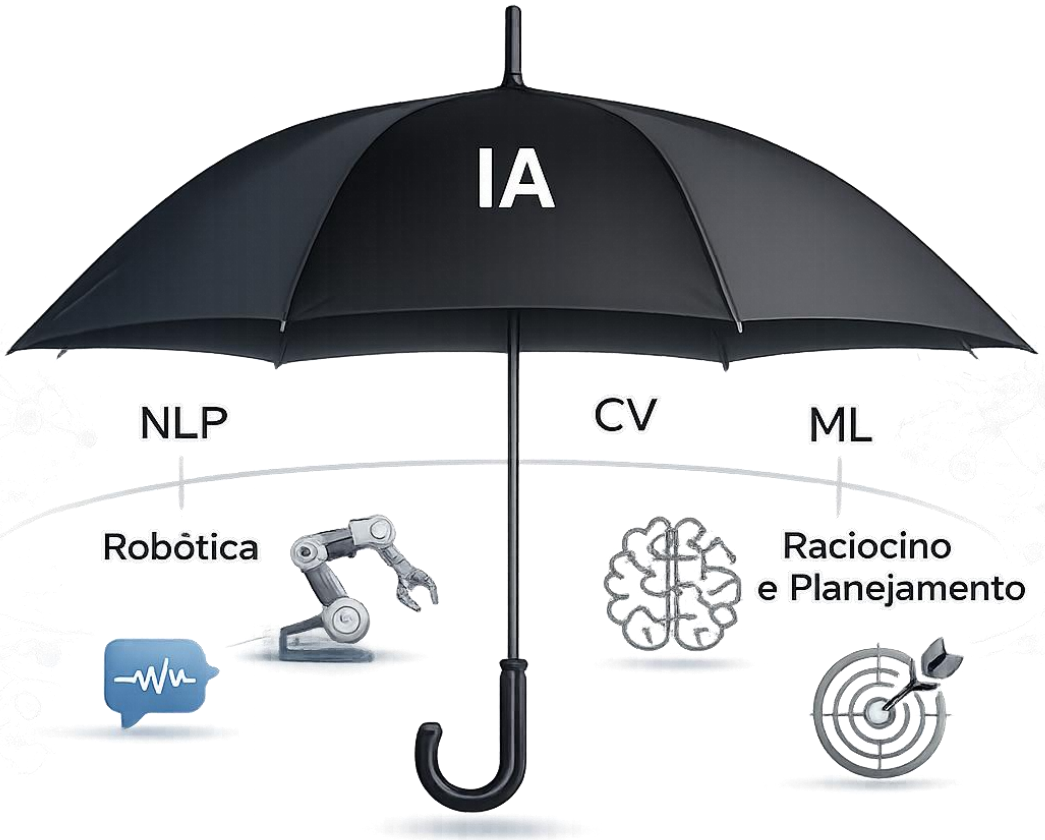
Motivação

→ EdgeML vs TinyML

Diferenciação de hardware e terminologia



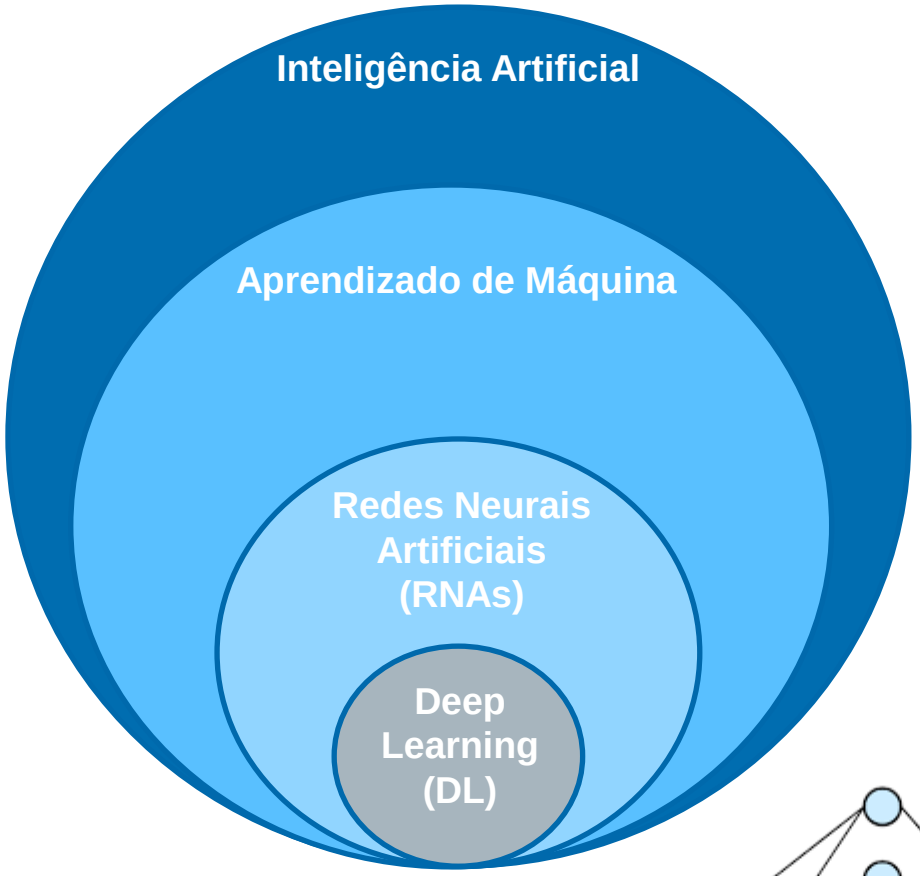
Definição de IA e ML

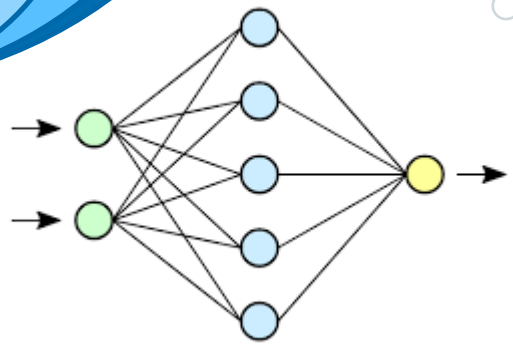


- **IA**: técnicas que façam as **máquinas emularem as capacidades humanas**.
  - Visão,
  - Fala,
  - Aprendizado,
  - Movimentação,
  - etc.,

- **ML**: algoritmos que **aprendem uma tarefa sem serem explicitamente programados para tal**.

Definição de IA e ML





- **RNAs**: modelos **inspirados no funcionamento do cérebro humano**.
- Consistem em **neurônios artificiais interconectados**, que são **organizados em camadas** e capazes de **aprender a partir de experiências prévias**.
- **DL**: modelos que aprendem padrões complexos usando redes neurais com várias camadas (i.e., profundas).
  - Por terem **maior capacidade**, **necessitam de grandes quantidades de dados** e **muitos recursos computacionais** para aprender.

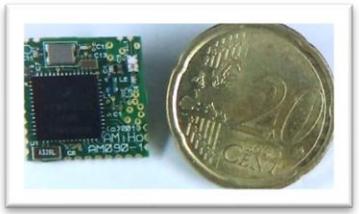
E se nós pudéssemos executar aplicações baseadas em ML nesses dispositivos com restrições computacionais?

O que poderíamos fazer?



















Aplicações

Manutenção preventiva

→ **Aplicação**: ***monitoramento contínuo*** de equipamentos com o objetivo de ***prever falhas***.

→ **Sensores que podem ser utilizados**: movimento, corrente, áudio e câmera.







Aplicações

Monitoramento e rastreio de bens

→ **Aplicações**:

- Monitoramento da saúde de animais e lavouras.
- Detecção de doenças em plantações.
- Detecção de incêndios.

→ **Sensores que podem ser utilizados**: movimento, temperatura, humidade, posição, acústico e câmera.









Aplicações

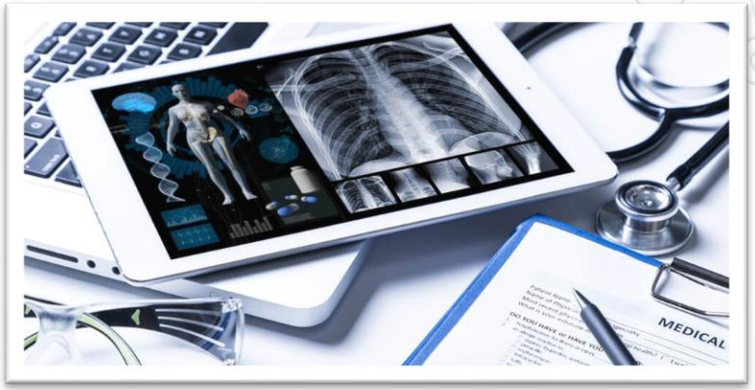
E-health

→ **Aplicações**:

- Detecção de fibrilação arterial em sinais eletrocardiograma.
- Detecção de doenças pulmonares (e.g., COVID, pneumonia).
- Detecção de apneia do sono.
- Detecção de posturas incorretas.
- Previsão de hospitalização por insuficiência cardíaca

→ **Sensores que podem ser utilizados**: movimento, acústico, câmera e ECG.

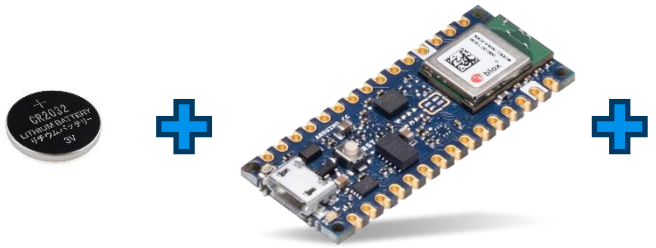






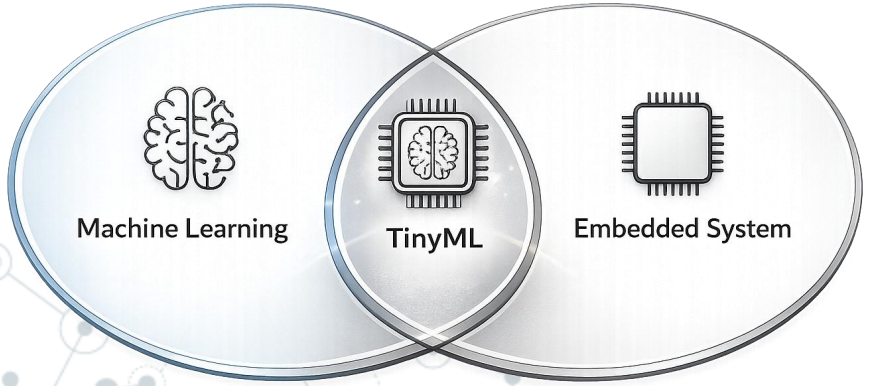
Sobre o Curso

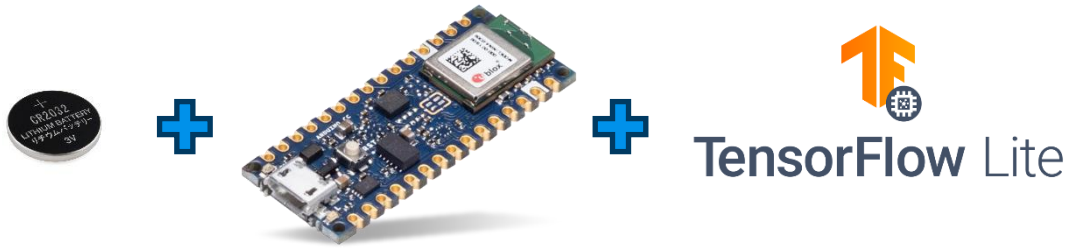
- A difusão de **dispositivos de moderado a baixo poder computacional**, com **(ultra)baixo consumo de energia**, **equipados com sensores**, juntamente com a introdução de **bibliotecas de ML para microcontroladores**, têm permitido a criação de dispositivos **IoT Inteligentes**, ou seja, que executam algoritmos de ML.
- Esse novo paradigma é chamado de **TinyML ou EdgeML**: **IoT + Sensores + ML**.
- **O paradigma envolve a implementação de modelos de ML e ferramentas de otimização para a execução desses modelos em dispositivos com restrições computacionais.**
  - Como sensores IoT, wearables e dispositivos portáteis.
- Envolve o **uso de algoritmos de ML leves** e a **redução do tamanho dos modelos** com o intuito de **otimizar do uso dos recursos computacionais** dos dispositivos.



Sobre o Curso

- O **processamento local** dos dados em **dispositivos de borda** traz alguns benefícios:
  - **Menor latência**: não é necessário o envio dos dados para um servidor na nuvem, possibilitando aplicações que operem em **tempo real**;
  - **Maior privacidade**: dados sensíveis não são transferidos para servidores;
- O **processamento local** dos dados em **dispositivos de borda** traz alguns benefícios:
  - **Menor dependência de conexões**: reduz ou elimina a necessidade de transferência de dados para servidores.
  - **Maior autonomia energética**: o uso de microcontroladores com baixo consumo de energia reduz o consumo de energia, uso de recursos e custos.





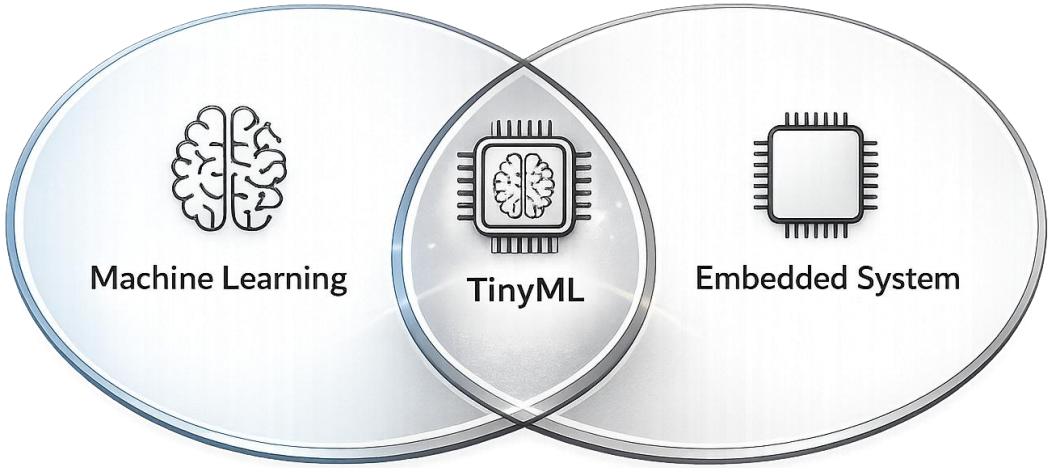
Sobre o Curso

- Portanto, o curso mistura **ML com dispositivos IoT**, cujas principais características são:
  - ✓ **Baixo poder computacional**: geralmente equipados com CPUs single core de 32 bits, poucos quilobytes de memória RAM e alguns megabytes de memória de longo prazo (*flash*).
  - ✓ **Baixíssimo consumo de energia:** são geralmente alimentados à bateria, as quais devem durar um longo período de tempo.
  - ✓ **Sensores**: temperatura, pressão, humidade, ópticos (e.g., câmeras RGB, térmicas), movimento (e.g., giroscópio e acelerômetro), biométricos (e.g., impressão digital, batimento cardíaco), etc.

- Nosso curso é baseado nos cursos de ***TinyML*** de Harvard e da UNIFEI.
  - https://scholar.harvard.edu/vijay-janapa-reddi/classes/cs249r-tinyml
  - https://github.com/Mjrovai/UNIFEI-IESTI01-TinyML-2022.1

Objetivos do Curso

- Apresentar os **principais algoritmos e técnicas de aprendizado de máquina** (Machine Learning, ML) aplicados a **dispositivos com recursos computacionais limitados**.
- **Familiarizar** os alunos com a **literatura e os conceitos-chave da área de Edge/TinyML**.
- Capacitar os alunos a **conceber, treinar e implantar aplicações Edge/TinyML em sistemas embarcados** (e.g., smartphones e dispositivos IoT).
- Proporcionar **experiência prática por meio de laboratórios e projetos**, permitindo que os alunos apliquem os conhecimentos adquiridos em cenários do mundo real.

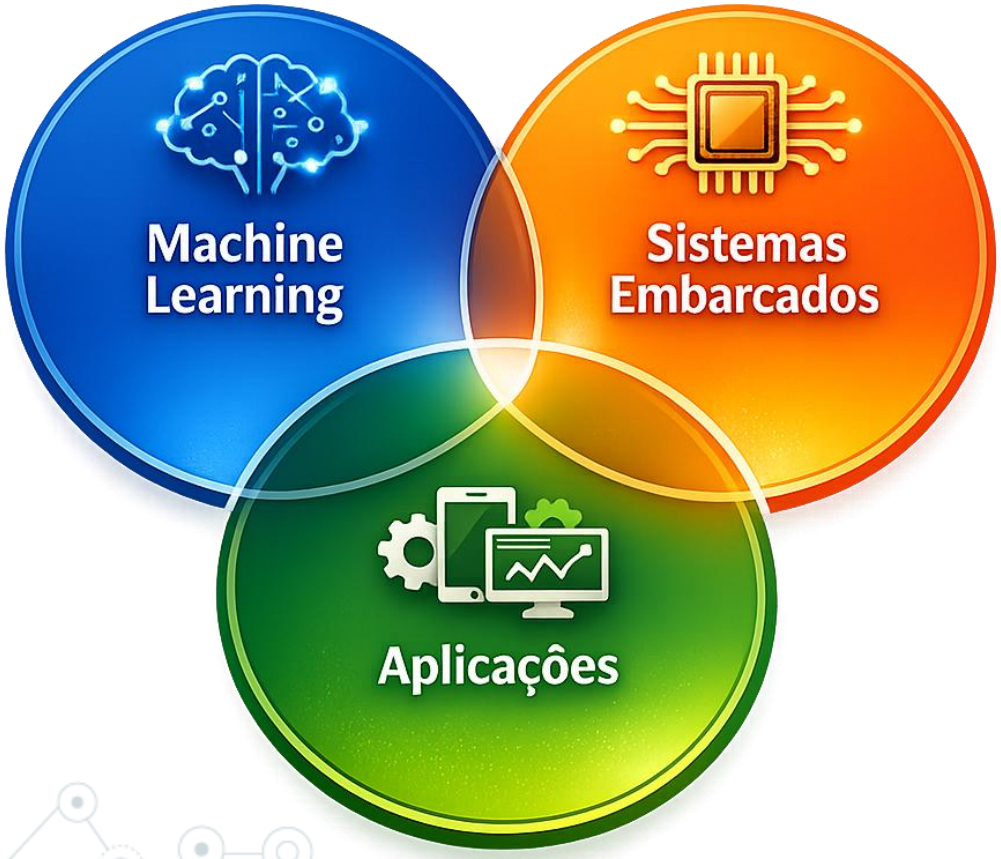


Objetivos do Curso

- O curso terá **duas partes**, uma introdutória e outra prática.
- A **primeira parte** conterá **aulas introdutórias sobre dispositivos embarcados, IoT e ML.**
- A **segunda parte** conterá **laboratórios e estudos dirigidos** para fixação dos conceitos introduzidos, além de um projeto final.
- Ao final do curso, vocês deverão ser capazes de entender e aplicar os principais algoritmos e técnicas de ML em aplicações práticas utilizando dispositivos com restrições computacionais.

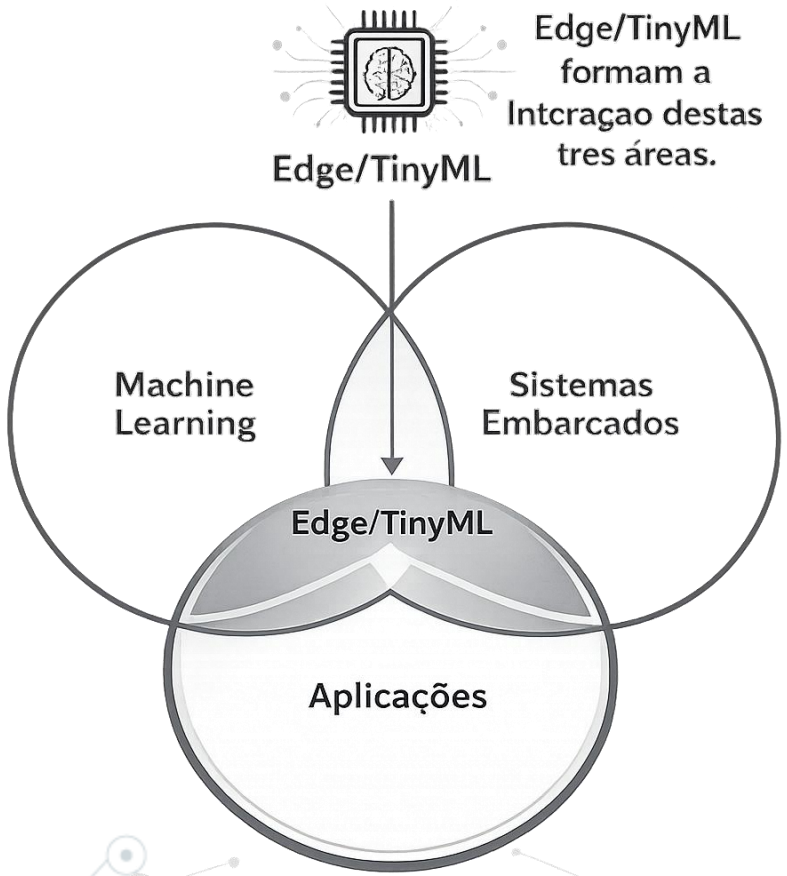


O Que Vamos Aprender?



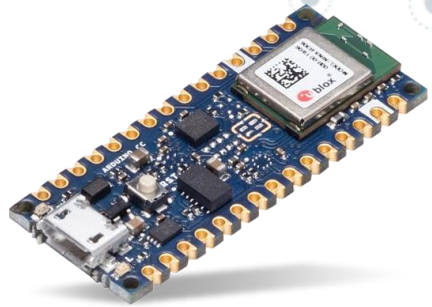
- Focaremos no aprendizado de conceitos para a construção de **aplicações** que apresentem:
  - ✓ Baixa latência;
  - ✓ Maior autonomia energética;
  - ✓ Eficiência computacional;
  - ✓ Baixo consumo de memória.

O Que Vamos Aprender?



- Trabalharemos na **interseção das três áreas ao lado**, dando origem ao **Edge/TinyML**.
- Para isso, devemos levar em consideração algumas questões importantes:
  - ✓ Quais **novos casos de uso são habilitados com o uso de Edge/TinyML**, que não eram possíveis antes?
  - ✓ Quais são os **desafios de implementar ML em dispositivos com recursos limitados?**
    - Temos que considerar restrições como **consumo de energia e memória** e **tempo de processamento**.

O Que Vamos Aprender?







→ Hardware

- Smartphones
- Arduino Nano 33 BLE Sense
- Kits de desenvolvimento
  - Raspberry Pi, Orange Pi, etc.
- Sensores

TensorFlow

ARDUINO

jupyter

EDGE IMPULSE

→ Software

- **Bibliotecas de ML**: Tensorflow, TFLite e TFLite Micro.
- **Ambientes de programação**: Google Colab (com Jupyter notebooks) e Arduino IDE.
- **Ambiente de desenvolvimento de ML**: Edge Impulse Studio.

Kit TinyML

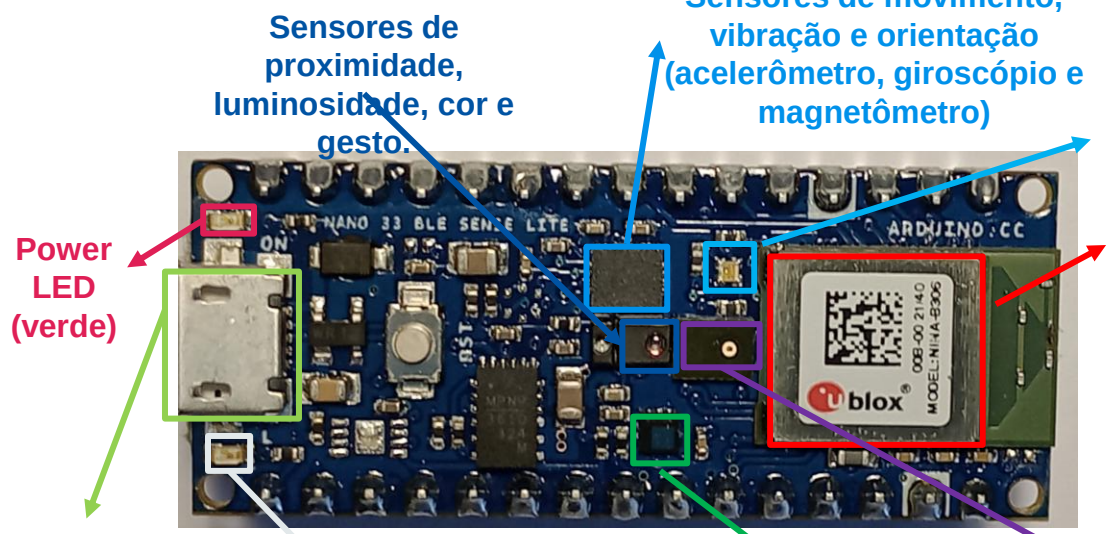


O kit contém:

- 1 x Arduino Nano 33 BLE Sense ***Lite****
- 1 x Shield
- 1 x Câmera OV7675
- 1 x Cabo USB A



Câmera de 0.3 Mega Pixels
Resoluções (pixels): 640x480 (VGA), 320x240 (QVGA) e 160x120 (QQVGA)
Frames por segundo: 30 (VGA), 60 (QVGA) e 240 (QQVGA)



Sensores de proximidade, luminosidade, cor e gesto.

Sensores de movimento, vibração e orientação (acelerômetro, giroscópio e magnetômetro)

LED RGB programáve l

Nordic nRF 52840
- **CPU: ARM Cortex M4 de 32 bits**
- **Freq.: 64 MHz**
- **Memória: 1 MB de Flash e 256 KB RAM**
- **Protocolos: BLE, NFC e Zigbee**

Power LED (verde)

Porta micro-USB

LED laranja programáve l

Sensor de pressão

Microfon e digital

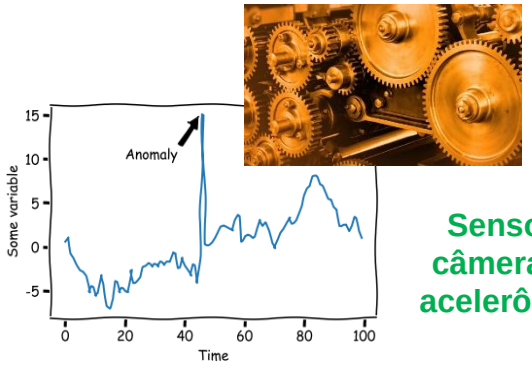
***** Sem sensor de temperatura e humidade.

Atividades Práticas



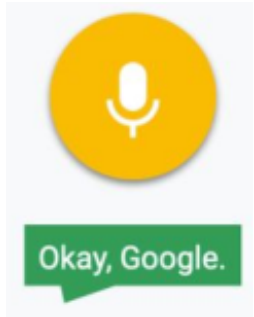
Classificação de movimento ou atividade

Sensores: acelerômetro, giroscópio, magnetômetro



Detecção/previsão de anomalias

Sensores: câmera e/ou acelerômetro.



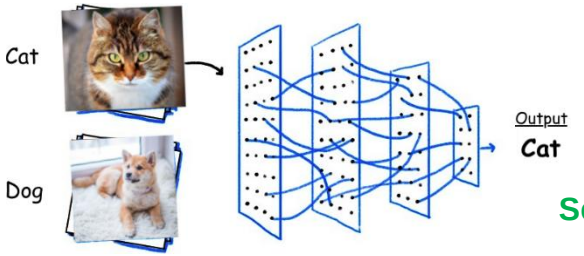
Keyword spotting

Sensor: microfone.



Visual wake imagens

Sensor: câmera.



Classificação de imagens

Sensor: câmera



Classificação de gestos

Sensores: câmera e/ou acelerômetro.



Pré-Requisitos

- Conceitos básicos de ***álgebra linear*** (e.g., matrizes e vetores), ***cálculo*** (e.g., algoritmos de otimização, como o gradiente descendente), ***probabilidade e estatística*** (e.g., distribuições de probabilidade, média, variância, desvio padrão) e ***processamento de sinais*** (e.g., FFT, filtragem);

- Conhecimentos de programação em C/C++ e Python.

EDGE IMPULSE

TensorFlow Lite



Linguagem Python

- Grande parte do curso necessitará de conhecimentos sobre a linguagem de programação Python, os quais eu assumo que vocês já têm.
- Assim, como primeira atividade, peço que vocês resolvam alguns exercícios sobre programação Python como forma de avaliar seus conhecimentos.
- Caso vocês sintam dificuldades em resolvê-los, me procurem, pois posso sugerir cursos e livros.

- **Estes exercícios valem nota!**
- O link para resolução dos exercícios via Google Colab segue abaixo:
  - https://colab.research.google.com/github/zz4fap/tp557-iot-ml/blob/main/exercises/Exerc%C3%ADcios_sobre_Programa%C3%A7%C3%A3o_em_Python.ipynb

Avaliações

→ **Atividades Extras (A):** 25%
- Exercícios de programação
- Entregas Parciais do Projeto Final

→ **Relatórios dos Laboratórios (R):** 25%
- Laboratórios com experimentos práticos.

→ **Projeto final (P):** 50%
- **Projeto prático unindo IoT e ML.**
- Até dois (2) alunos por projeto.
- Tema deve ser escolhido por vocês.

NF = A*25% + R*25% + P*50%

Referências

[1] Daniel Situnayake and Pete Warden, “TinyML: Machine Learning with TensorFlow Lite on Arduino and Ultra-Low-Power Microcontrollers”, 1st ed., O'Reilly Media, 2019.

[2] Aurélien Géron, “Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems”, 1st ed., O'Reilly Media, 2017.

[3] Agus Kurniawan, “IoT Projects with Arduino Nano 33 BLE Sense: Step-By-Step Projects for Beginners”, Apress, 2020.

[4] Stuart Russell and Peter Norvig, “Artificial Intelligence: A Modern Approach”, Prentice Hall Series in Artificial Intelligence, 3rd ed., 2015.

[5] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. “Deep Learning”, MIT Press, 2016.

[6] Hakima Chaouchi, “The Internet of Things: Connecting Objects”, Wiley, 2010.

[7] Jun Zheng and Abbas Jamalipour, “Wireless Sensor Networks: A Networking Perspective”, Wiley, 2009.

[8] Coleção de livros

AULAS ?

Avisos

- **Todo material do curso está disponível no Teams.**

- Google Colab + Python Crash Course
  - https://www.youtube.com/watch?v=inN8seMm7UI&ab_channel=TensorFlow
  - https://www.youtube.com/watch?v=inN8seMm7UI
  - https://www.youtube.com/watch?v=pq4NNIYar9o&list=PLRc6ZYt68prVXAhwY1JD6DFc3BJGmJriq&pp=gAQBiAQB

- Introdução ao TensorFlow
  - https://www.youtube.com/watch?v=yjprpOoH5c8&ab_channel=TensorFlow

- **Horário de Atendimento:**
  - Todas as quintas-feiras das 16:30 às 17:30.
  - Presencialmente ou remotamente.

Ideias de Projetos

- Detectando falhas em automóveis através de seu som
- Identificação de pragas
- Identificação de posturas incorretas
- Inspeção automática de qualidade
- Classificador de Vogais em Libras
- Detecção de doença pulmonar
- Detecção de algarismos em hidrômetros
- Detecção de Roncos
- Detecção de tumores cancerígenos
- Detecção e prevenção de abalos sísmicos
- Detecção de incêndios

Ideias de Projetos

- Identificação de falhas em rolamentos
- Identificação de doenças respiratórias
- Detecção de COVID através da tosse
- Detecção do uso de máscaras
- Personal Trainer
- Predição da qualidade do ar
- Diabetic retinopathy detector
- https://www.tensorflow.org/lite/examples?hl=pt-br
- https://experiments.withgoogle.com/collection/tfliteformicrocontrollers
- “Explore real-world edge ML projects”, http://tinyurl.com/tinymlprojects

Atividades:

- **Exercícios:** Programação em Python.
  - **Data de Entrega:** 19/08/2026
- **Definição de Tema do Projeto**
  - **Data de Entrega:** 19/08/2026
- **Validação da Contribuição/Novidade do Projeto**
  - Levantamento Bibliográfico
  - Escrita da Introdução, Trabalhos Relacionados e Objetivo do Projeto.
  - **Data de Entrega:** 02/09/2026 --- **APRESENTAÇÃO**

Atividades:

- **Bases para Levantamento Bibliográfico:**
  - Web – Para levantamento de soluções comerciais
  - IEEEXplore
  - Springer
  - MDPI
  - Wiley
  - Elselvier



Obrigada pela Atenção!

Dúvidas?

victoria.souto@Inatel.br