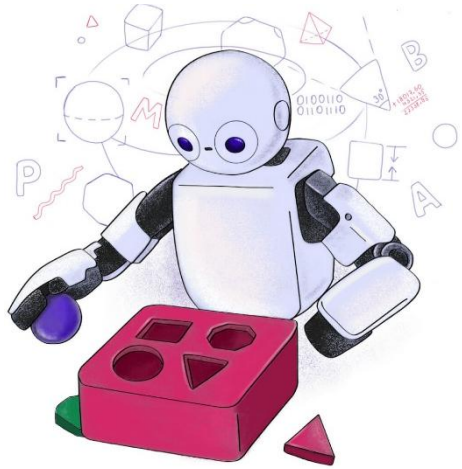
TP557 - Tópicos avançados em IoT e Machine Learning:

Detecção de anomalias



Inatel

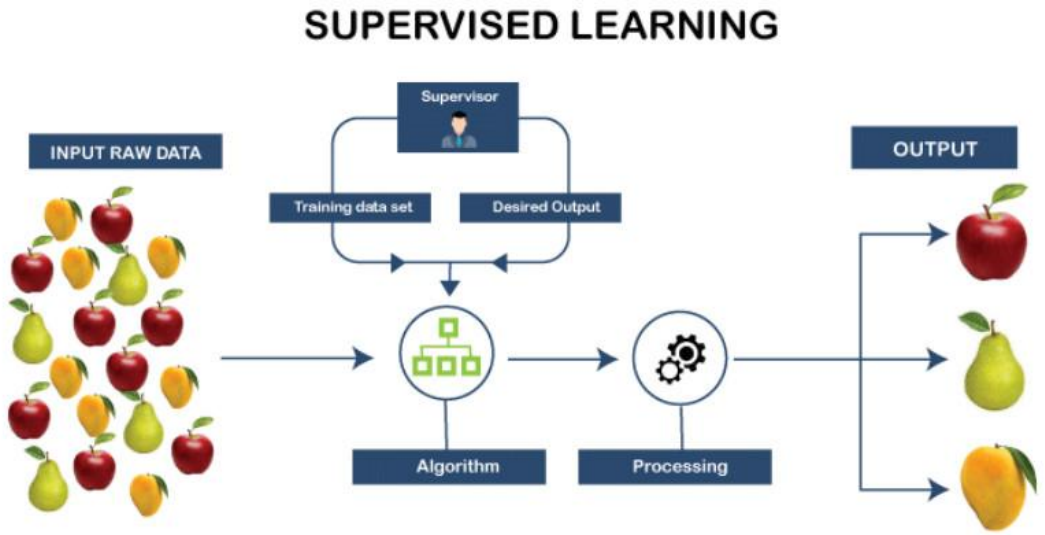
Samuel Baraldi Mafra
samuelbmafra@inatel.br

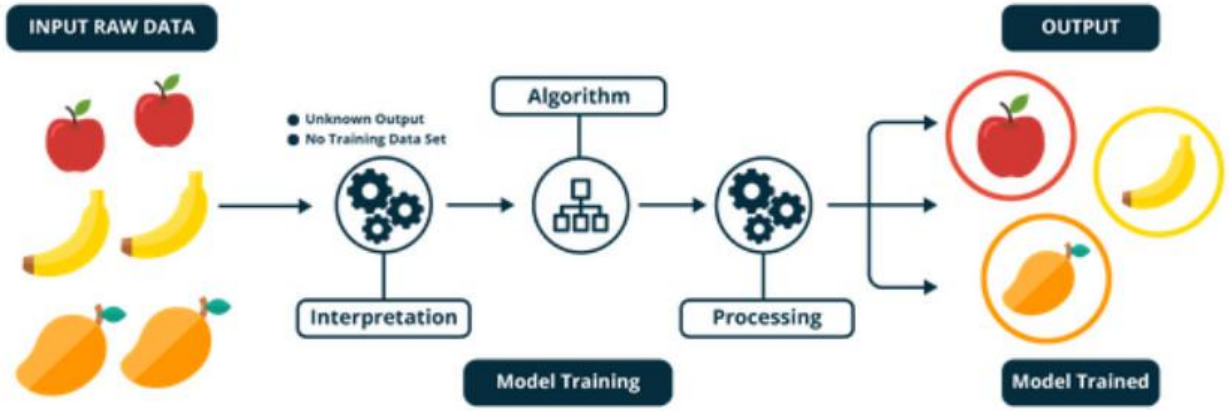
Aprendizado não-supervisionado

- Diferentemente do aprendizado supervisionado, no aprendizado não-supervisionado, ***não existem rótulos***.
- Esses algoritmos ***descobrem padrões ocultos ou agrupamentos de dados*** sem a necessidade de rótulos.
- São usados em problemas de
  - Segmentação
  - Agrupamento (i.e., *clusterização*)
  - Redução de dimensionalidade
  - ***Detecção de anomalias***

Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

Aprendizado supervisionado versus não supervisionado

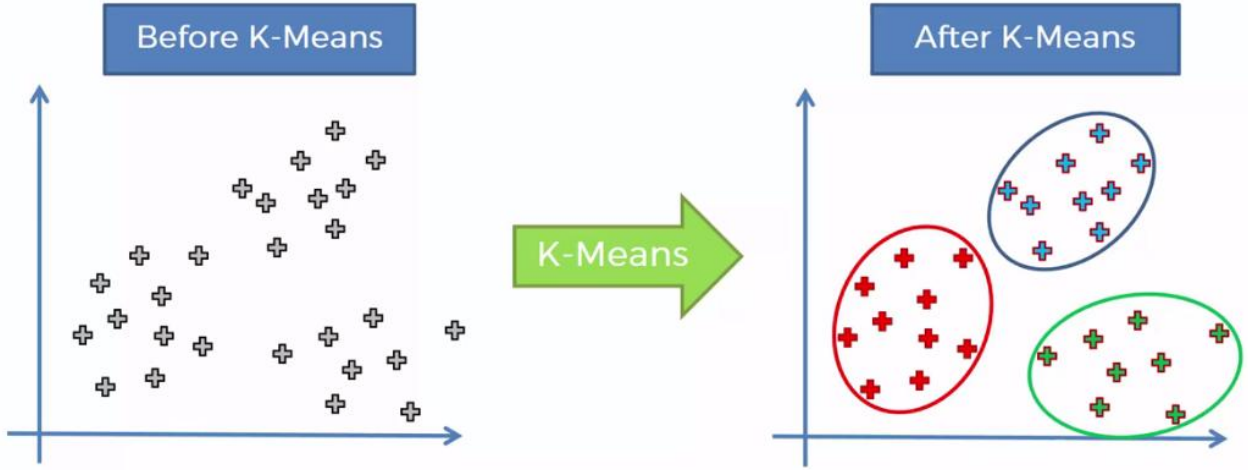




Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

Clusterização

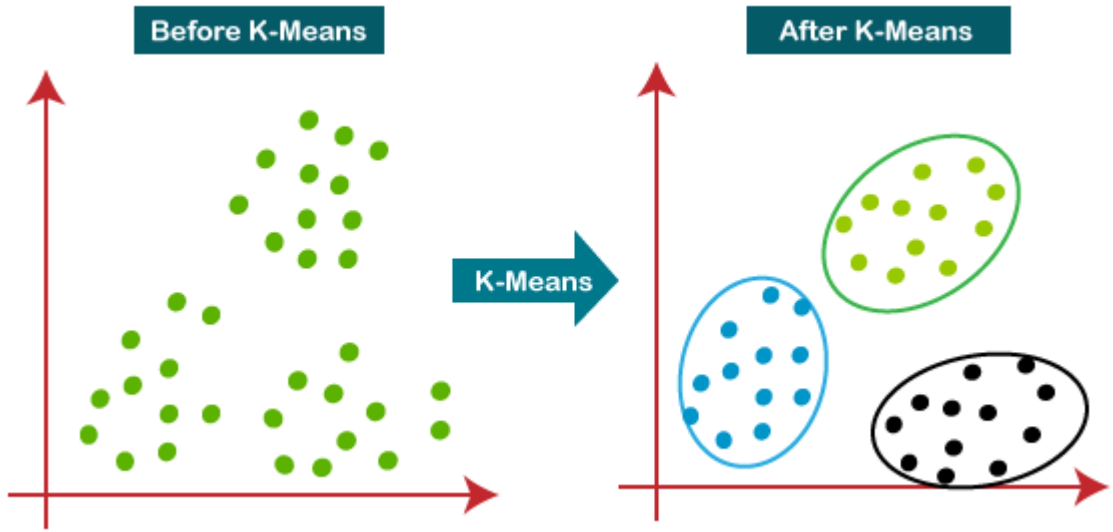
- A forma mais simples e conhecida de aprendizado não-supervisionado é a clusterização ou agrupamento.
- O objetivo do agrupamento é ***dividir os dados em vários grupos ou clusters***, de modo que as amostras dentro de cada grupo sejam ***mais comparáveis entre si e diferentes das amostras dentro dos outros grupos***.
- É essencialmente um ***agrupamento de amostras com base em quão semelhantes (ou próximos)*** e diferentes elas são entre si.



Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

K-means

- O algoritmo de clusterização mais conhecido é o K-means.
- O objetivo do K-means é simples: ***agrupar amostras semelhantes*** e descobrir padrões subjacentes.
  - Semelhante aqui é no sentido de ***proximidade***.
- Para atingir este objetivo, o K-means procura um número fixo (k) de clusters em um conjunto de dados.



Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

K-means

K-means pseudo-código

Entradas: conjunto de exemplos e número de clusters, k.

1. **Defina** k centroides iniciais (geralmente, feito de forma aleatória).
2. **Repita**
   a) Calcule a distância de cada exemplo, $\boldsymbol{x}$, para cada um dos k centroides e atribua cada exemplo ao cluster mais próximo.
   b) Calcule o novo centroide de cada cluster*.
3. **Enquanto** as posições dos centroides continuarem mudando.

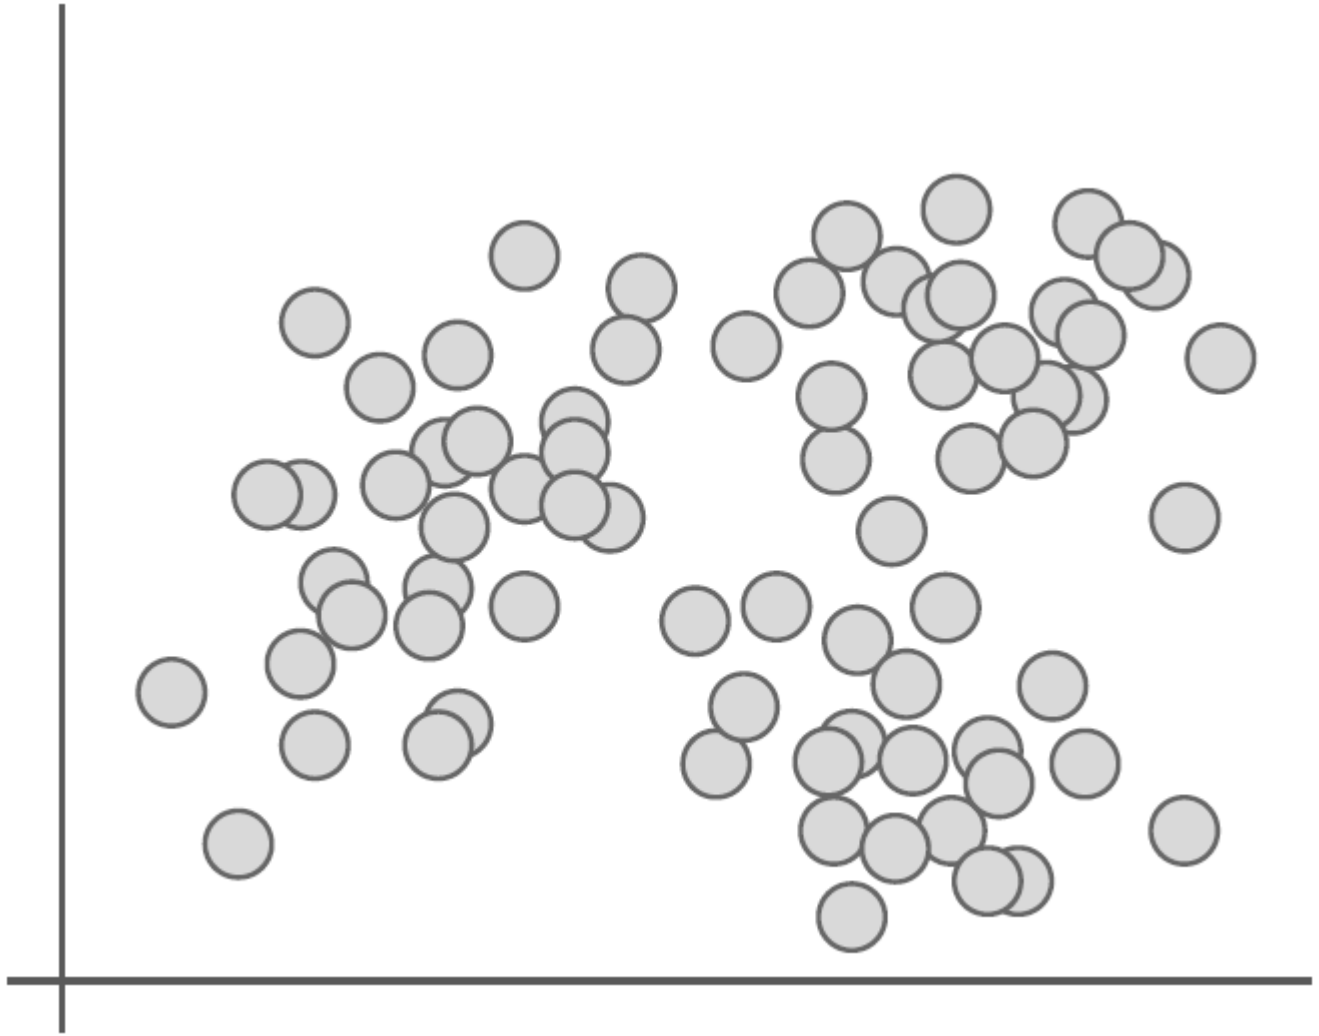
*os novos centroides são calculados como a média aritmética (centro geométrico) das amostras pertencentes a cada cluster.

Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

K-means

Funcionamento do K-means

1. Define-se o número de clusters, K = 3

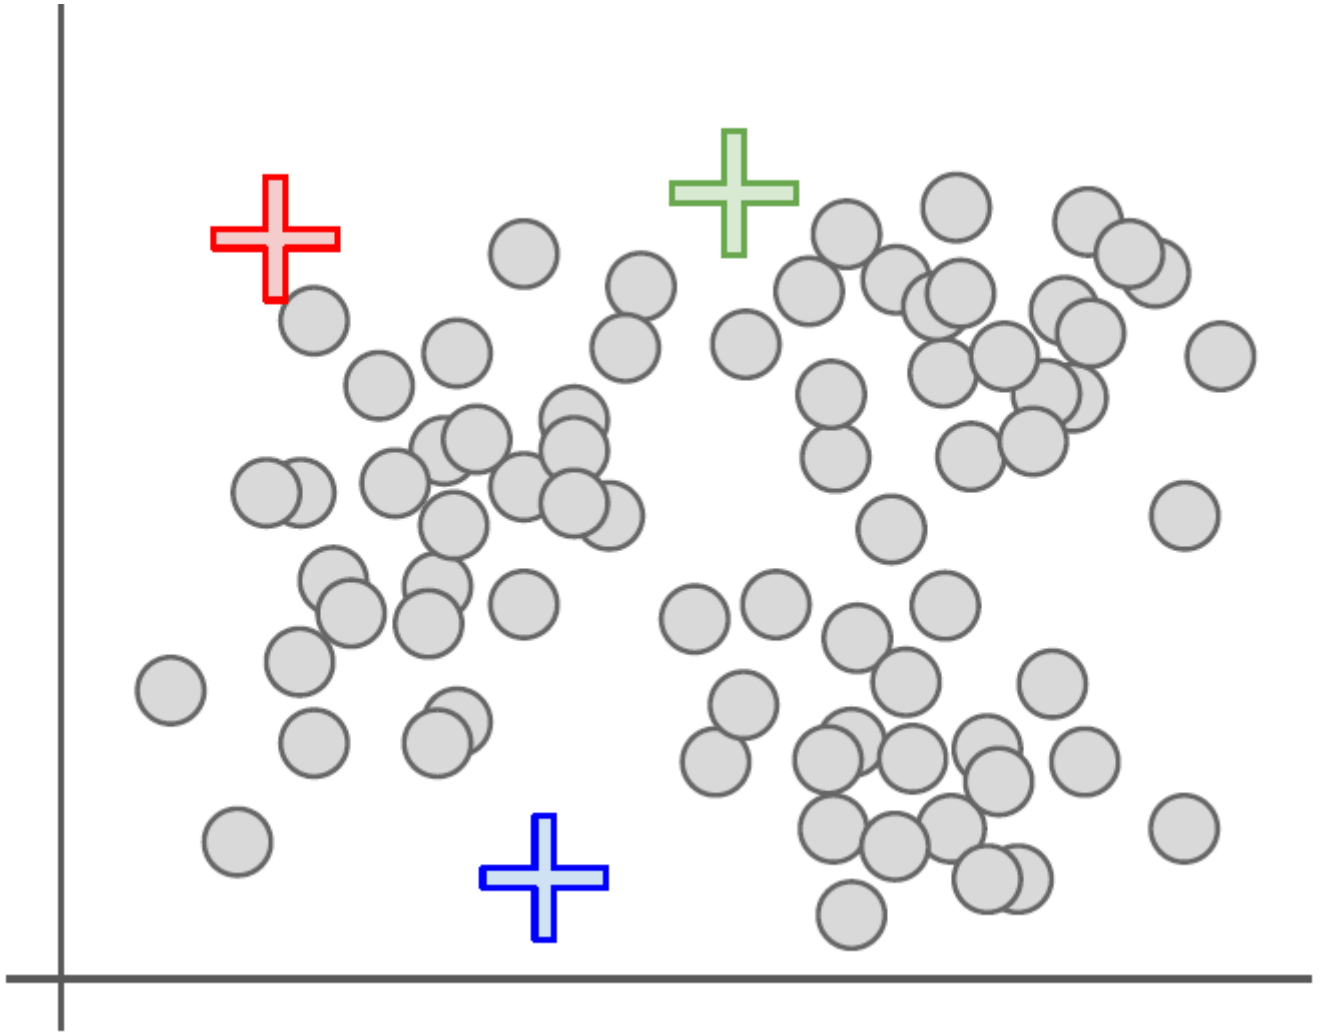


Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

K-means

Funcionamento do K-means

2. Escolhe-se os centroides para cada cluster de forma aleatória.

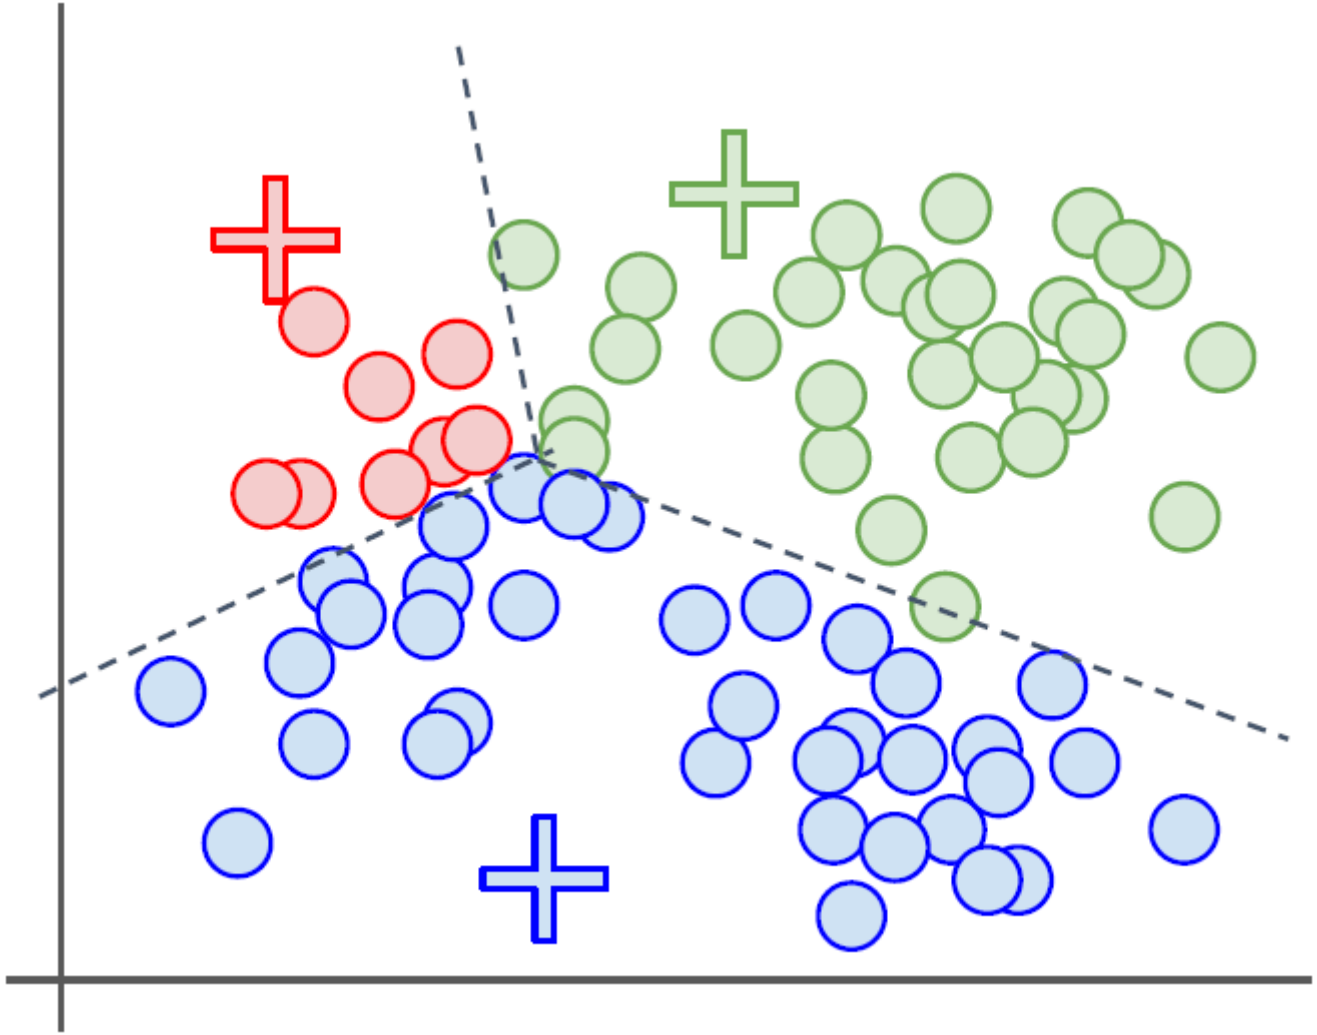


Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

K-means

Funcionamento do K-means

3. Atribui-se cada amostra ao centróide mais próximo com base na distância euclidiana.

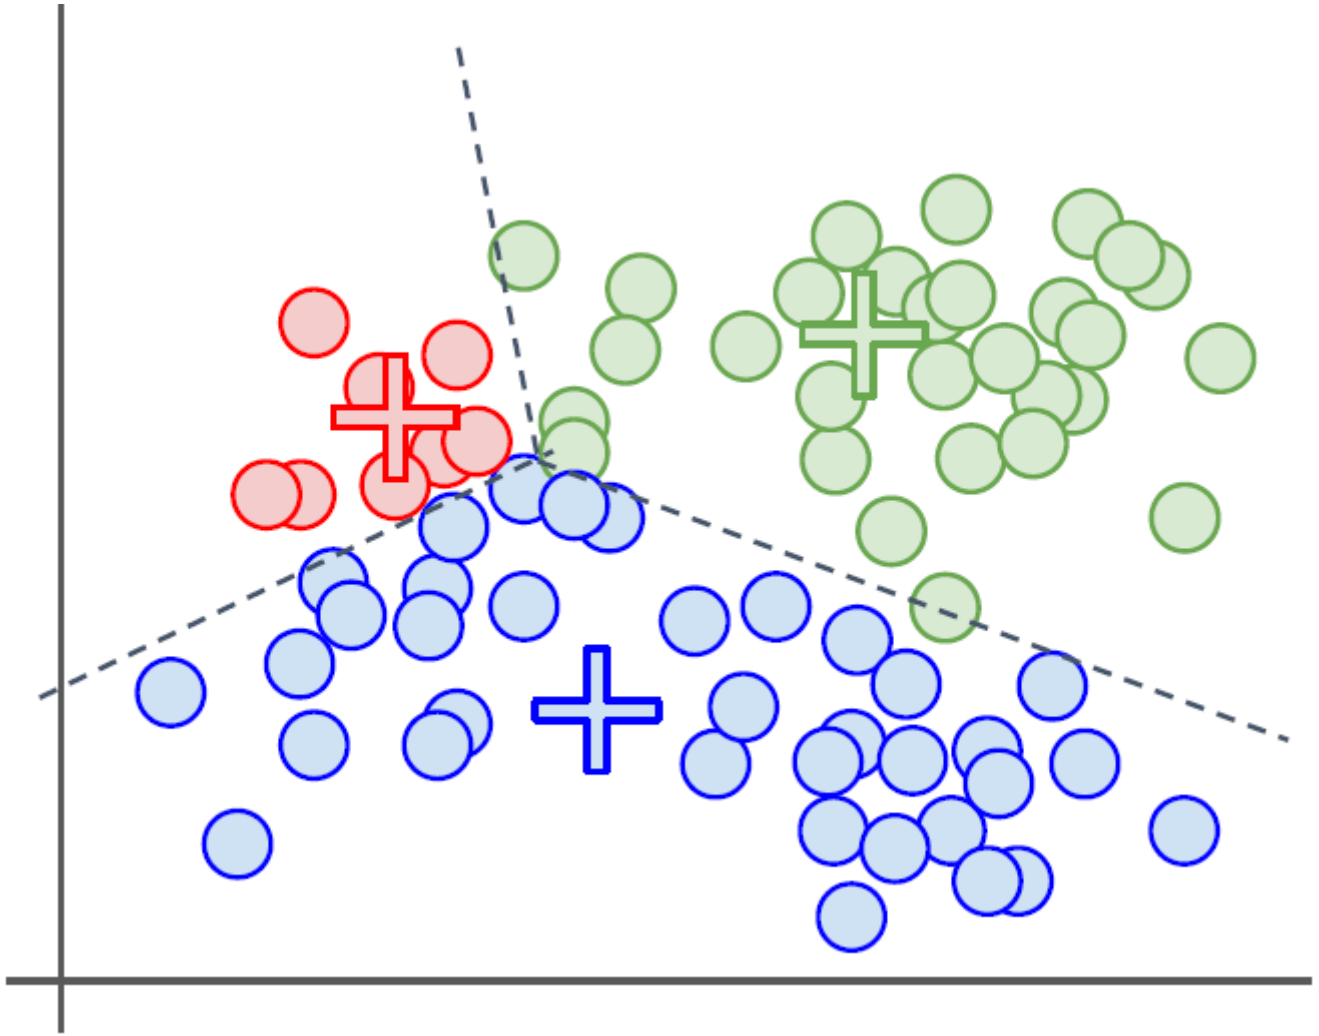


Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

K-means

Funcionamento do K-means

4. Recalcula-se o centroide dos clusters.

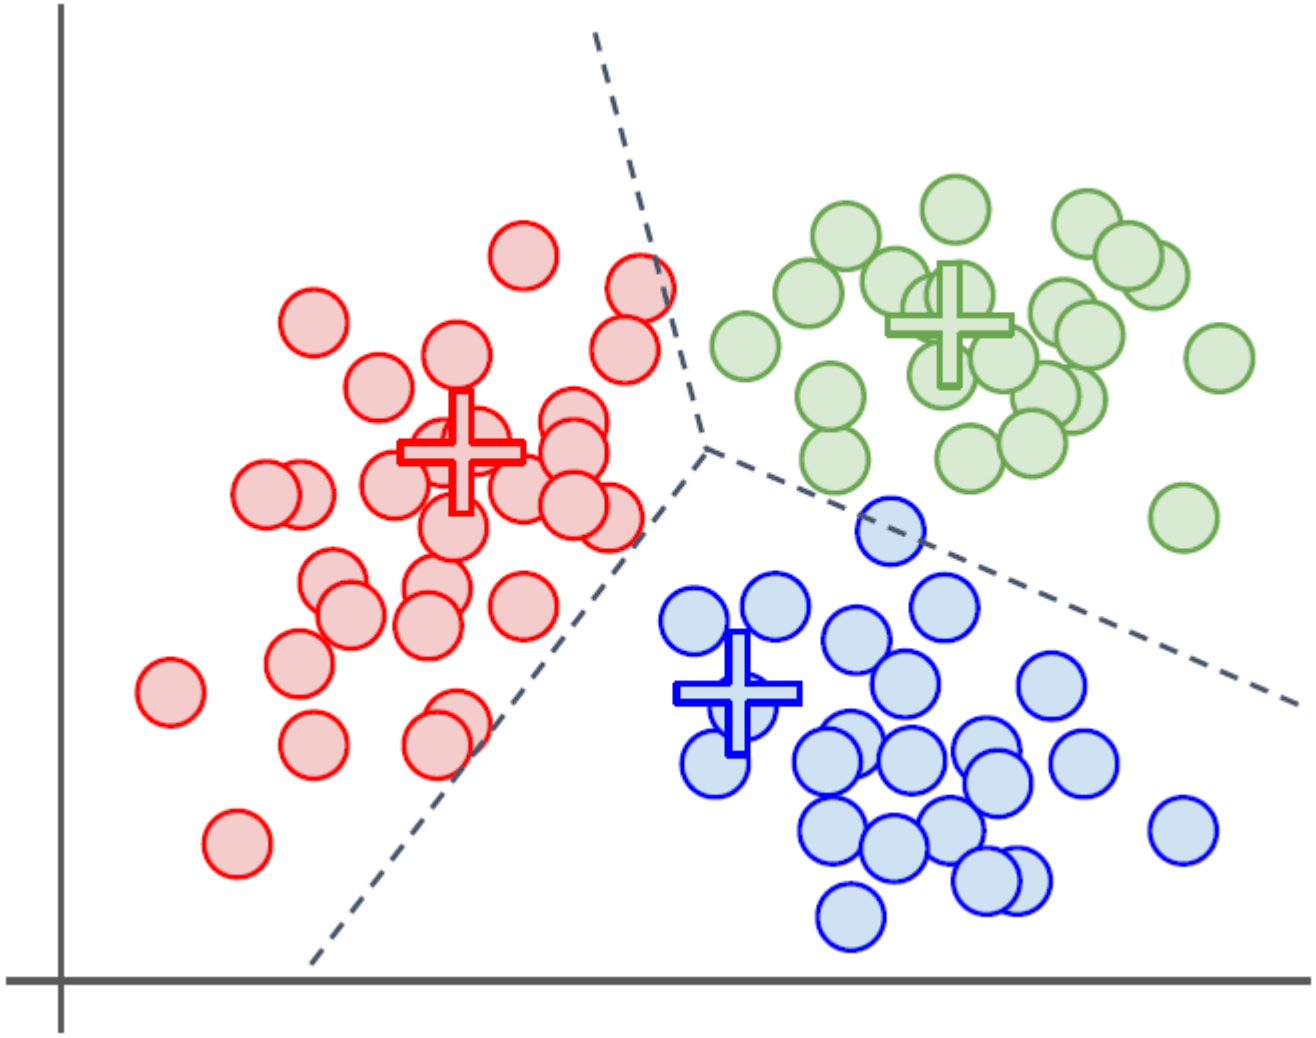


Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

K-means

Funcionamento do K-means

5. Repete-se os passos 3 e 4.

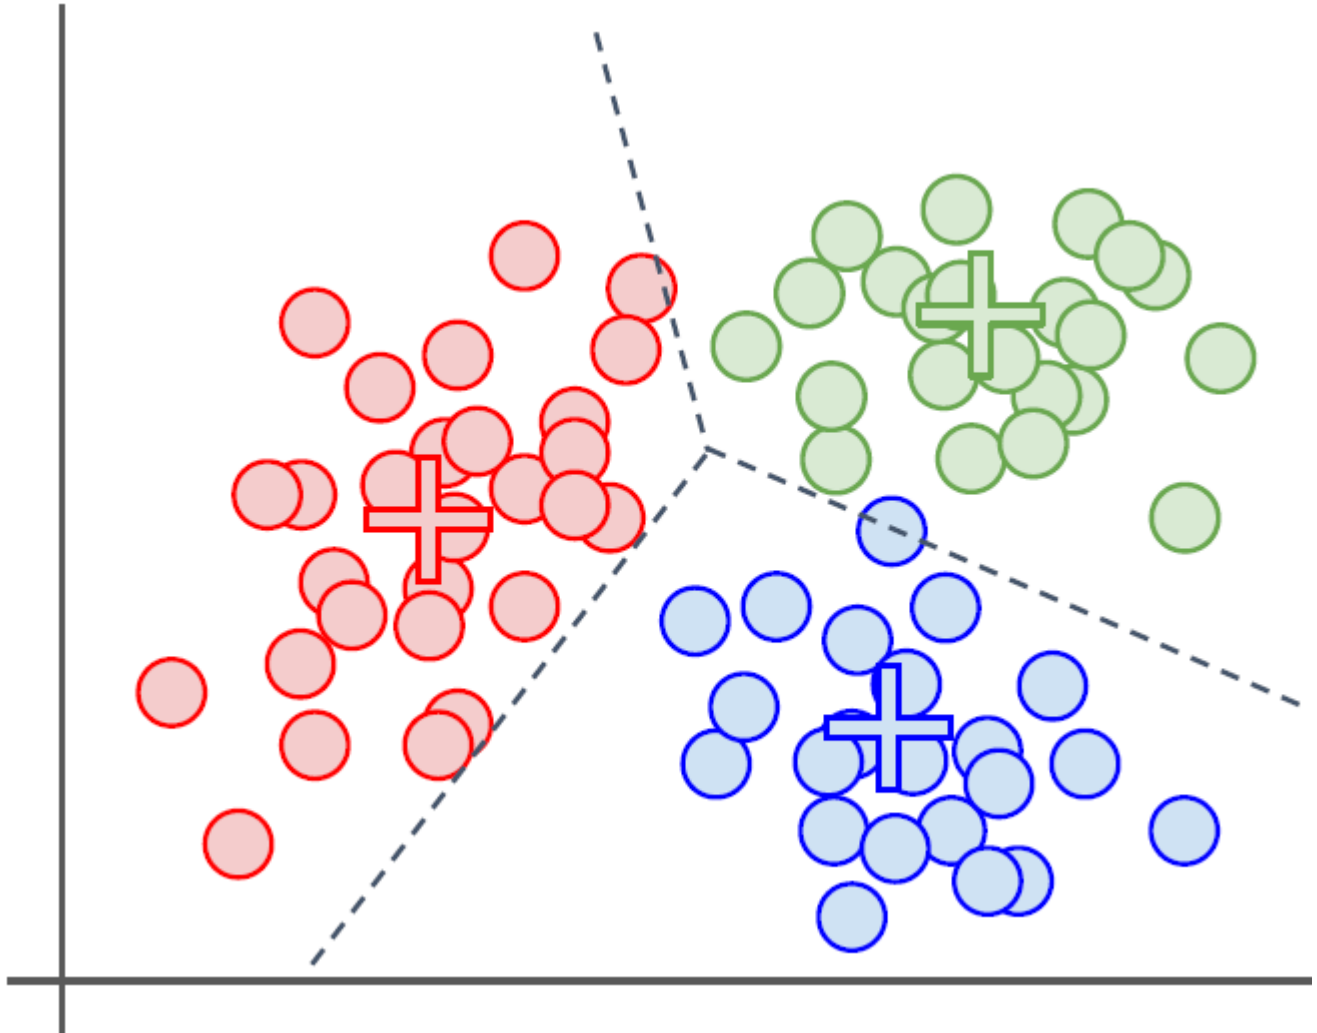


Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

K-means

Funcionamento do K-means

5. Repete-se os passos 3 e 4.



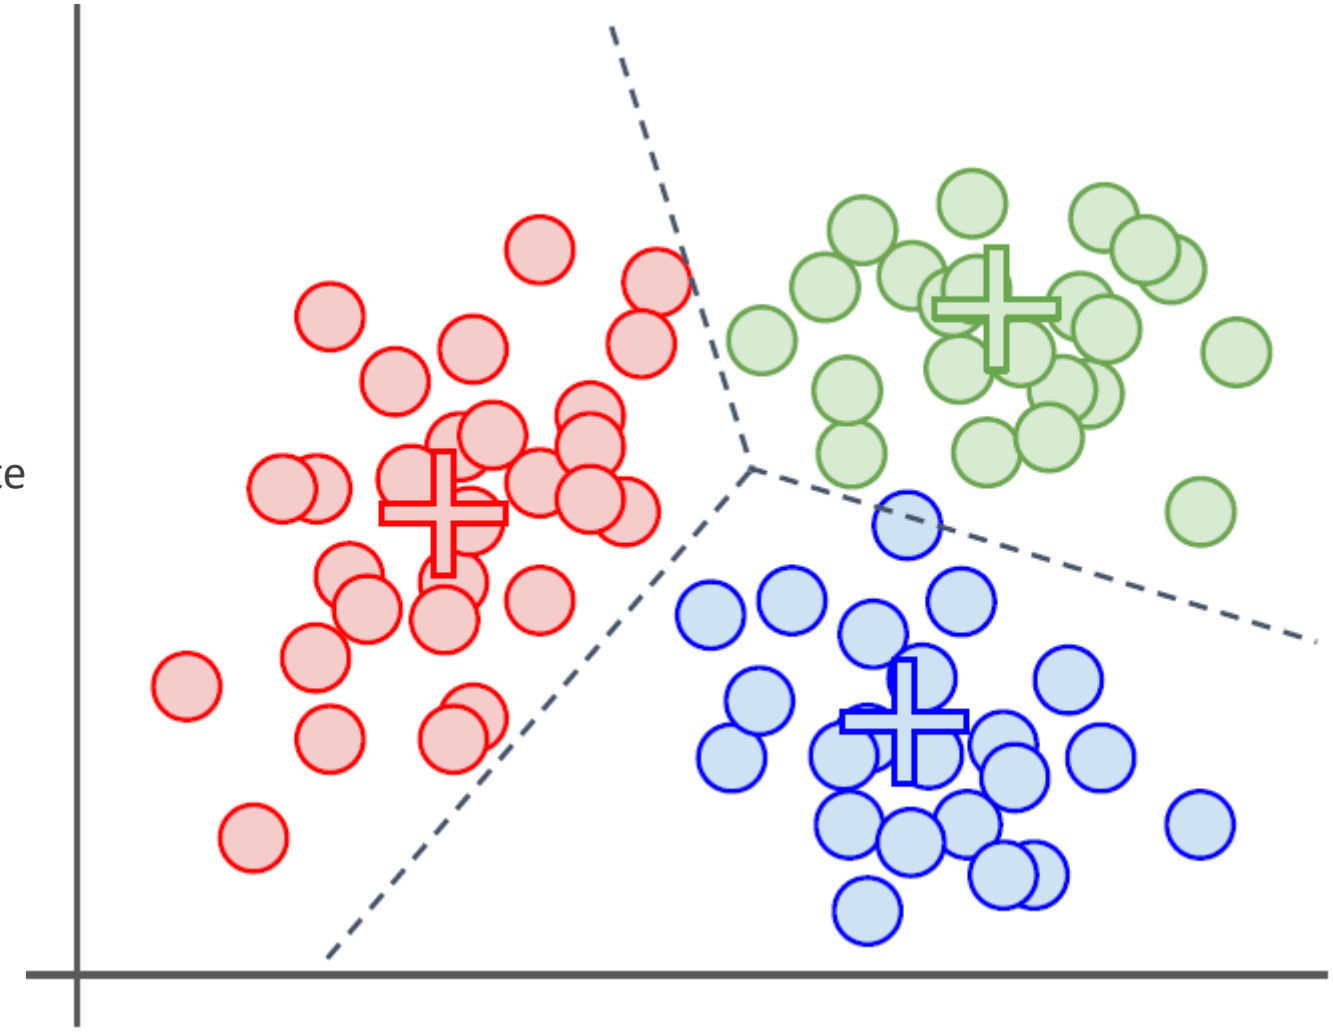
Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

K-means

Funcionamento do K-means

Repete-se os passos 3-4 até que um dos casos abaixo ocorra:

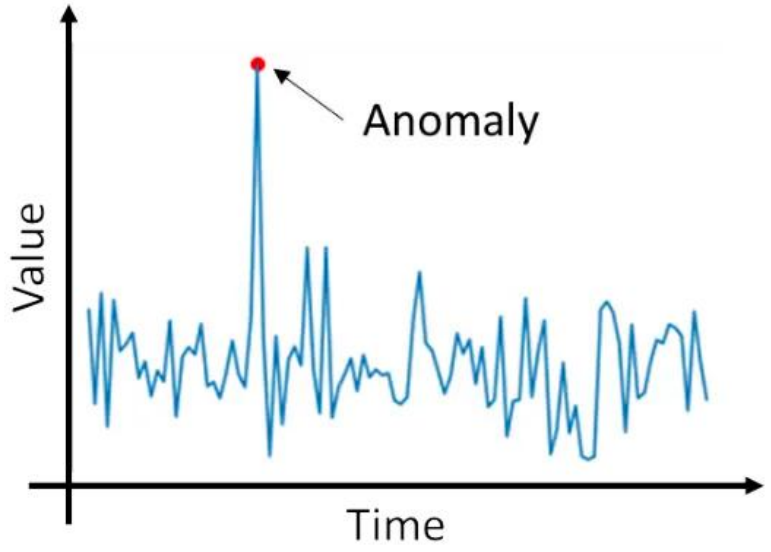
1. A soma das distâncias entre as amostras e o centroide correspondente seja minimizada
2. Não haja alteração nos centroides
3. O número máximo de iterações seja atingido

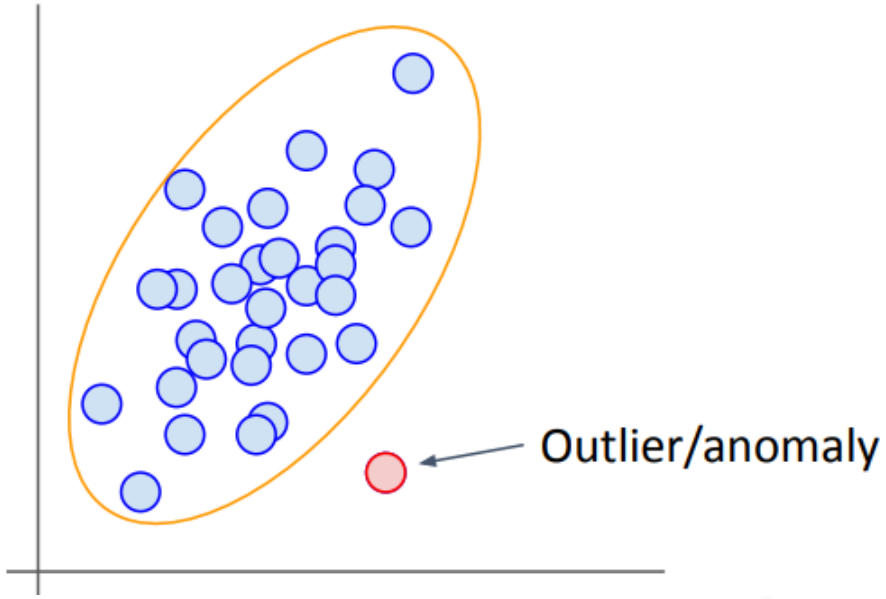


Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

Detecção de anomalias

- A detecção de anomalias é a identificação de itens, eventos ou observações raras que levantam suspeitas por diferem significativamente da maioria dos dados.
- Exemplos
  - Detecção de spam
  - Detecção de fraude de cartão de crédito
  - Detecção de falhas em equipamentos
  - Detecção de movimentos anômalos

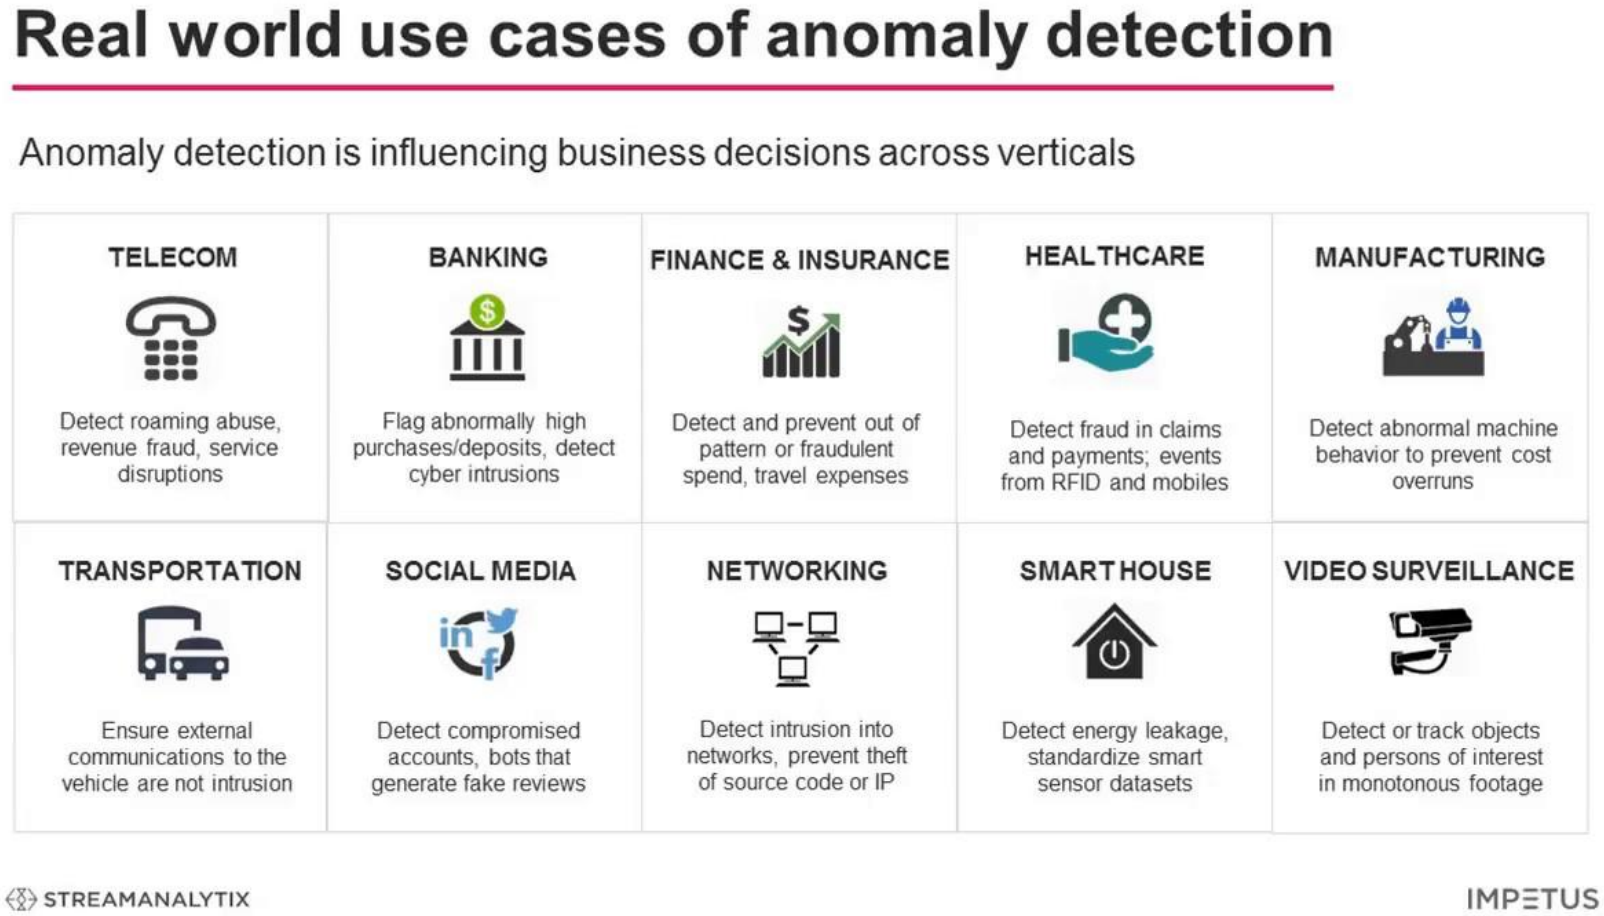




Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

Detecção de anomalias

- Aplicações

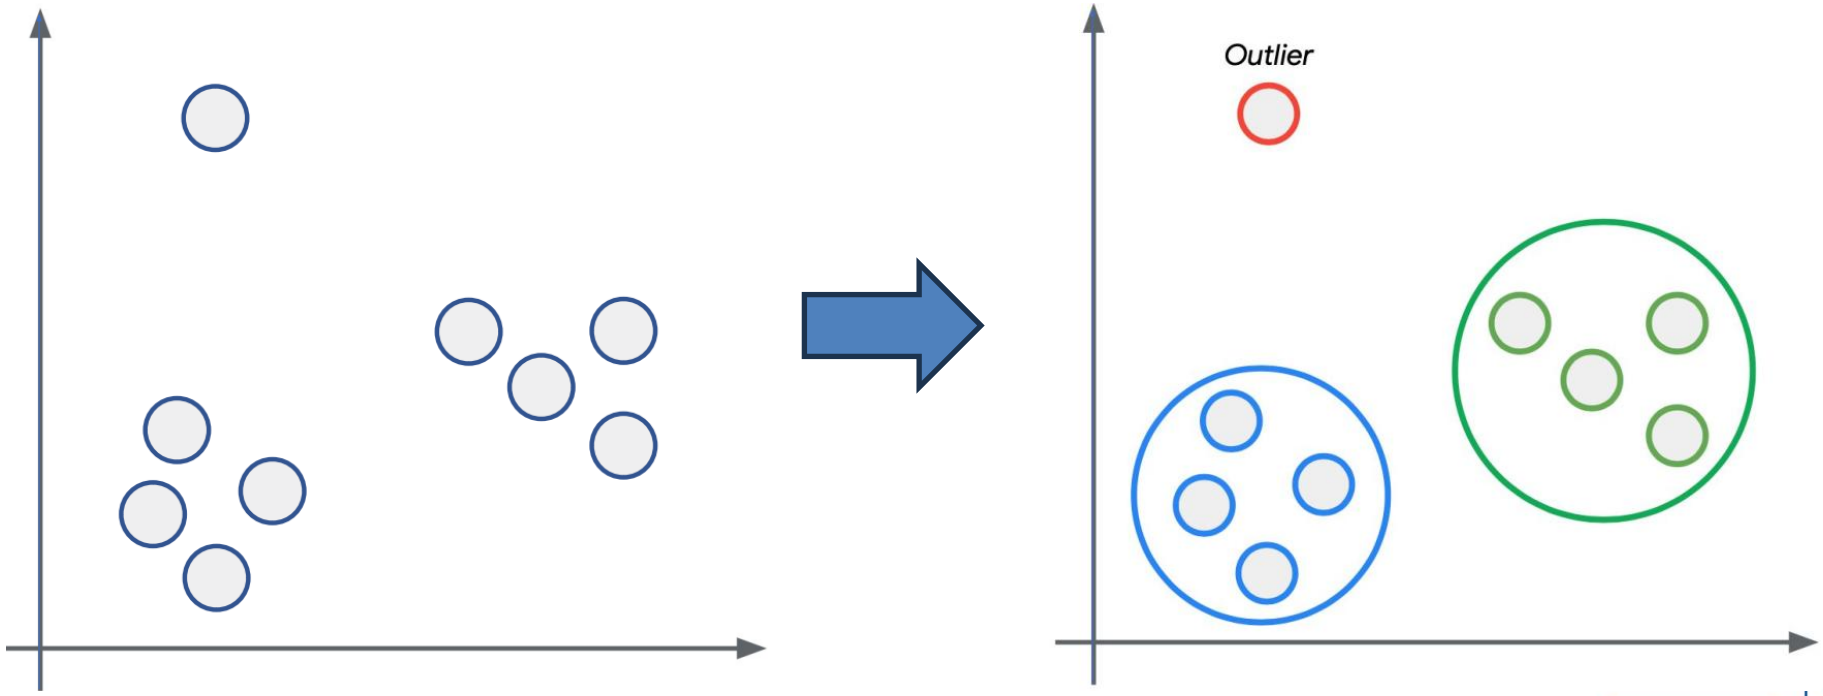


- Disrupção de serviços de telecom
- Compras fraudulentas
- Fraudes em pagamentos e pedidos de exames
- Comportamento anormal de máquinas
- Contas comprometidas
- Invasões em redes
- Vazamentos de água e energia
- Identificar objetos em imagens sem variação

Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

Detecção de anomalias

- Algoritmos
  - K-means usando a área do centroide
  - Isolation Forest
  - One-Class SVM
  - Local Outlier Factor
  - Etc.



https://scikit-learn.org/stable/modules/outlier_detection.html#overview-of-outlier-detection-methods

Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

K-means

- Exemplo: Escolha de Locais para centros de distribuição

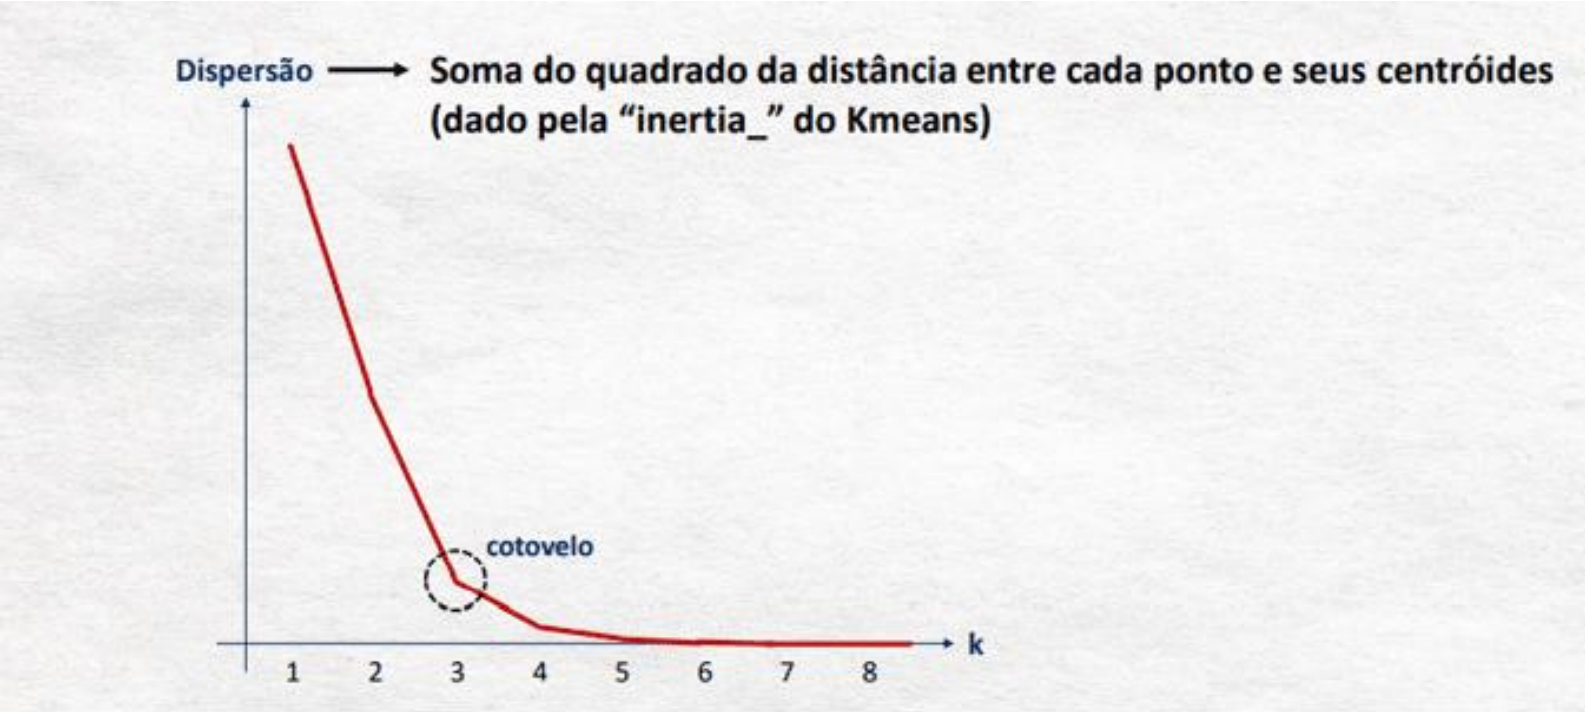




https://colab.research.google.com/github/zz4fap/tp557-iot-ml/blob/main/examples/k_means_centros_de_distribuição.ipynb

K-means

Como escolher o K ótimo?



$$\mathrm{WSS} = \sum_{i=1}^{N_C} \sum_{x \in C_i} d(\mathbf{x}, \bar{\mathbf{x}}_{\mathbf{C}_i})^2$$

Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

Detecção de anomalias

Movimentação de containers ao longo do ciclo logístico



Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

Detecção de anomalias

Movimentação de containers ao longo do ciclo logístico

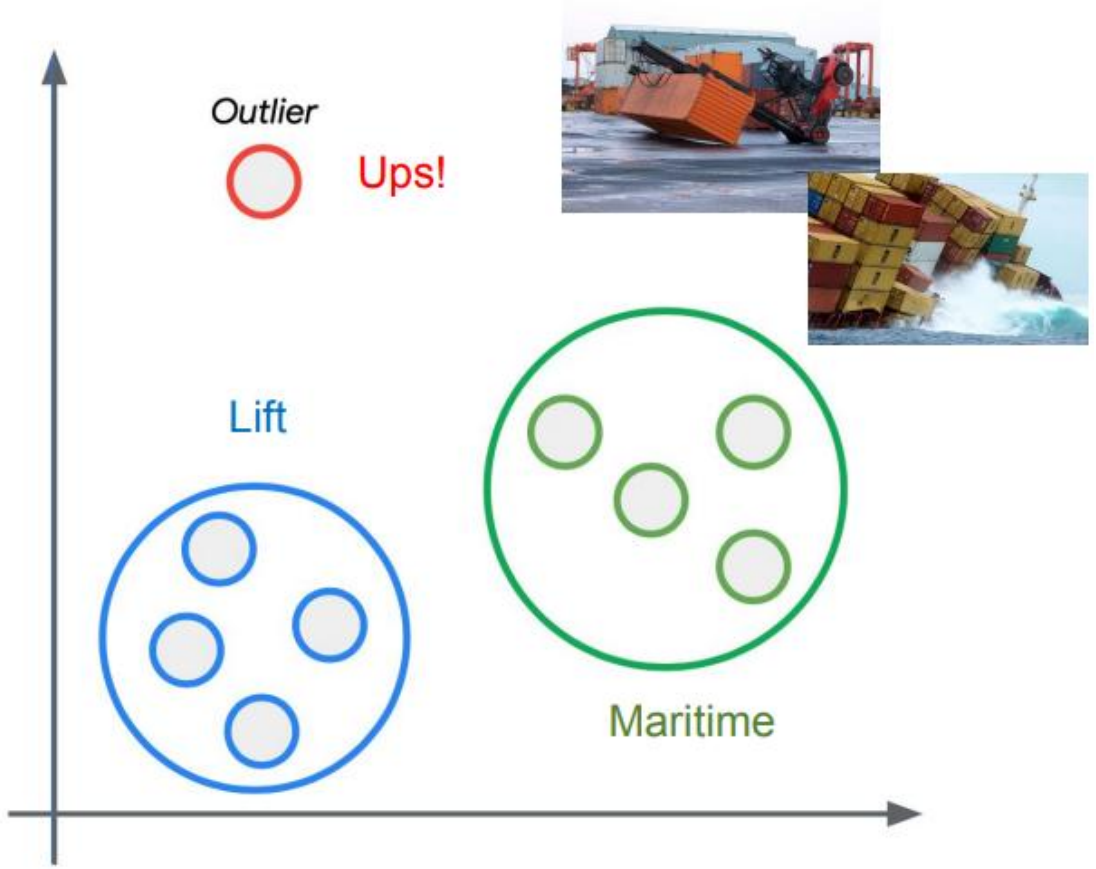
Classificação de 5 estados do container

- Parado
- Sendo erguido
- No mar
- No caminhão
- Anomalia (e.g., container caindo no mar, empilhadeira tombando)

Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

Detecção de anomalias

Detecção de anomalias com K-means

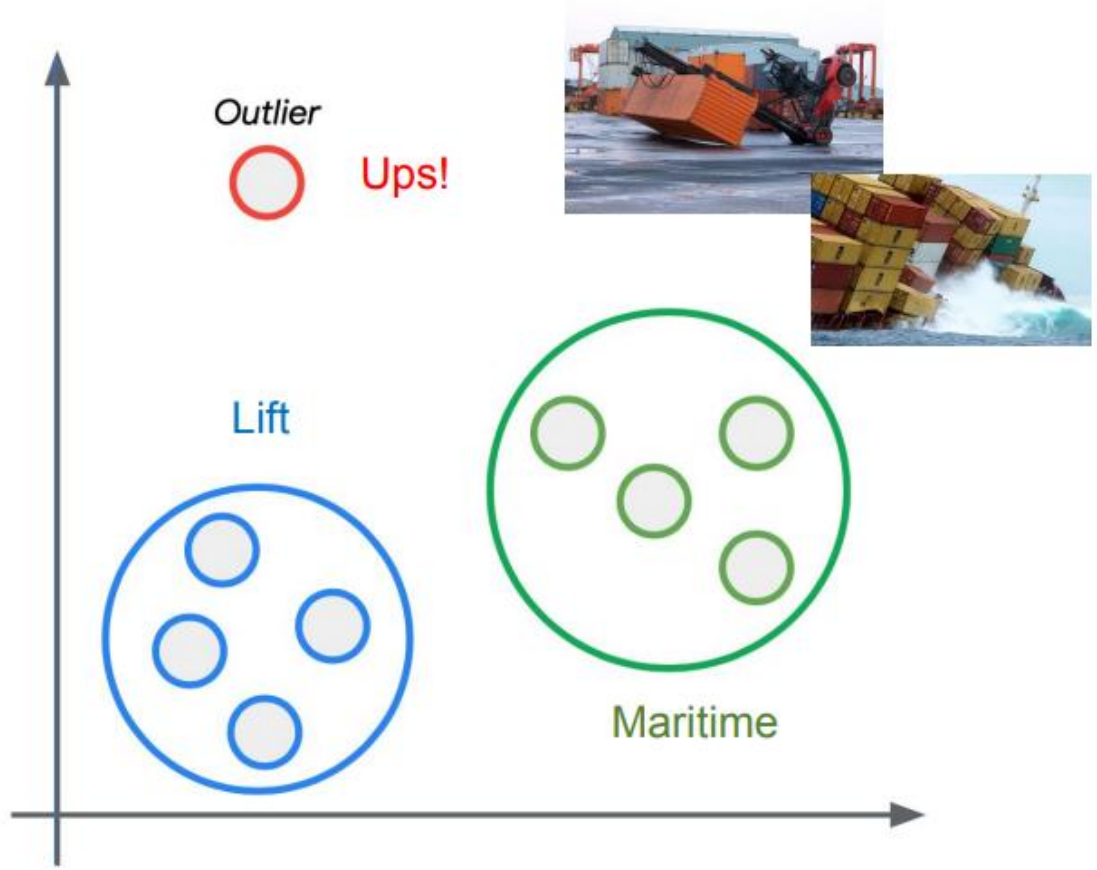


https://colab.research.google.com/github/zz4fap/tp557-iot-ml/blob/main/examples/k_means_anomaly_detection.ipynb

Detecção de anomalias

Trabalho:

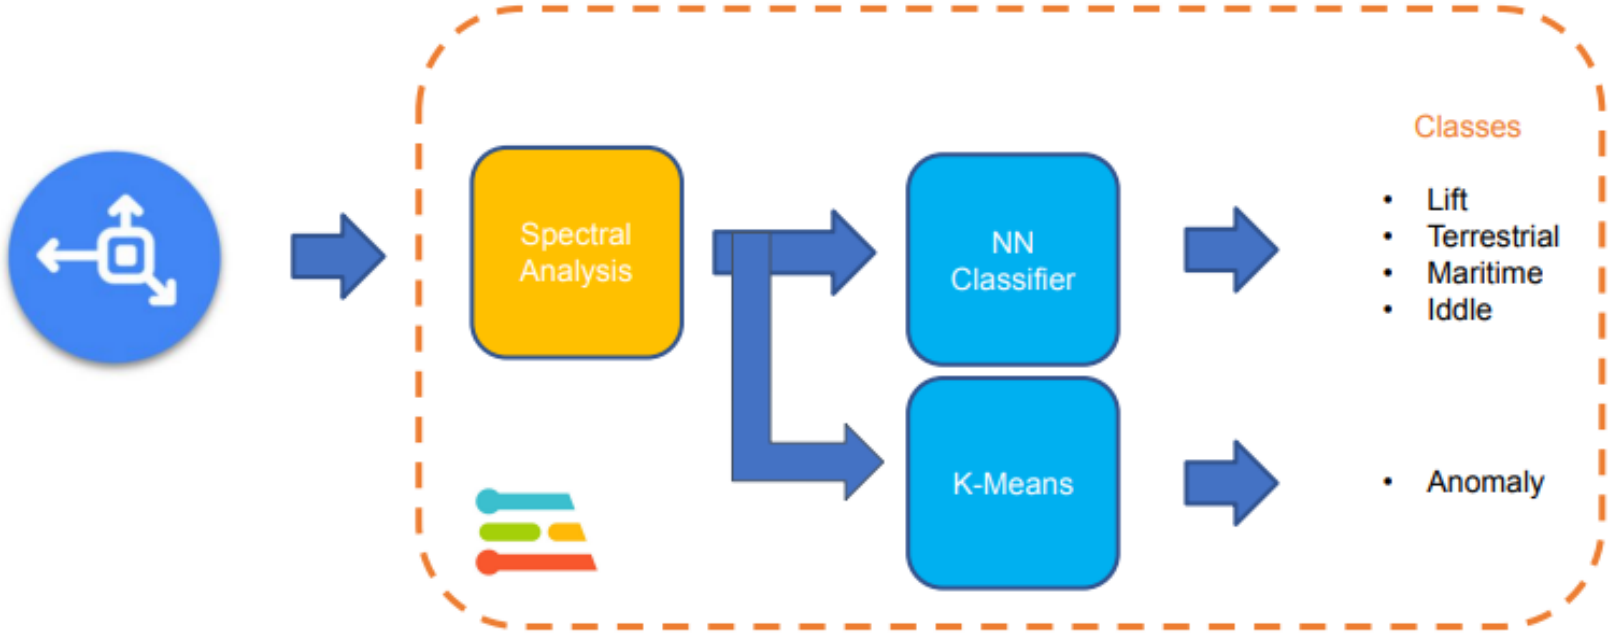
Incluir no Edge Impulse possíveis anomalias nos dados do ciclo logístico, e.g., quedas.



Detecção de anomalias

Trabalho:

Se baseie no seguinte tutorial: https://docs.edgeimpulse.com/docs/tutorials/end-to-end-tutorials/time-series/continuous-motion-recognition



Inatel
CAMINHOS QUE CONECTAM COM O FUTURO

Acompanhamento do trabalho final

Inatel
CAMINHOS QUE CONECTAM COM O FUTURO